Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук

Магистерская программа «Финансовые технологии и анализ данных»

КУРСОВАЯ РАБОТА

На тему (рус): Исследование влияния параметров методов оценки ошибок генерации диффузионных моделей

На тему (англ.): A Study on the Impact of Parameter Choices in Hallucination Evaluation Methods for Diffusion Models

Студент _____
Пахуров Фёдор Константинович (Ф.И.О., подпись)

Руководитель КР _____
Лукьянченко П. П., старший преподаватель (должность, звание, Ф.И.О, подпись)

Москва, 2026

Исследование влияния параметров методов оценки ошибок генерации диффузионных моделей

Курсовая работа (исследовательский проект)

Пахуров Фёдор Константинович
МФТАД251,
НИУ ВШЭ,
Москва, Россия
fpakhurov@gmail.com

Аннотация

Диффузионные модели порождают ошибки разной природы: синтетичность, низкоуровневые текстурные артефакты, структурное дублирование и семантические несоответствия. В работе систематически изучается влияние параметров лёгкого детерминированного дескриптора на основе кривых сложности–энтропии Реньи (CE) на оценку этих ошибок. Эвристическая метрика заменена воспроизводимым протоколом (логистическая регрессия, повторная кросс-валидация, бутстреп-интервалы, тест ДеЛонга, контроль доли ложных открытий). Раздельно проверены две гипотезы: различение реального и синтетического (H1) и различение удачных и неудачных генераций (H2). Гипотеза H1 подтверждается на выборках (AUROC до 0,86) и на CIFAKE (0,76); контроль источника при этом выявляет значимый конфаунд данных, а CE не превосходит спектр Фурье. Гипотеза H2 не подтверждается: ни одна из 44 конфигураций не превышает случайность. На основе нелокальных ординальных признаков построен лёгкий детектор дублирования, устойчивый к тоновой правке вставки.

Ключевые слова: сложность–энтропия, перестановочная энтропия, оценка ошибок генерации, диффузионные модели, детектор дублирования.

Abstract

Diffusion models produce errors of different natures: syntheticity, low-level texture artifacts, structural duplication, and semantic inconsistencies. This work systematically studies how the parameters of a lightweight deterministic descriptor based on Rényi complexity–entropy (CE) curves affect the evaluation of such errors. The original heuristic metric is replaced by a reproducible protocol (logistic regression, repeated cross-validation, bootstrap intervals, DeLong test, false-discovery-rate control). Two hypotheses are tested separately: distinguishing real from synthetic images (H1) and distinguishing successful from failed generations (H2). H1 holds on the collected samples (AUROC up to 0.86) and on CIFAKE (0.76); however, a source-confound control reveals a substantial data confound, and CE does not outperform a Fourier spectrum. H2 is not supported: none of 44 configurations exceeds chance. Building on non-local ordinal features, a lightweight duplication detector is proposed that is robust to tone editing of the pasted region.

Keywords: complexity–entropy, permutation entropy, generation-error evaluation, diffusion models, duplication detector.

Содержание

1 Введение 5

2 Обзор существующих подходов 6

2.1 Анализ интерполяции мод в латентном пространстве 6

2.2 Оценка через граф сцены и вопросно-ответную модель 6

2.3 Локальная диффузионная декомпозиция 6

2.4 Анализ сложности–энтропии 6

2.5 Сравнительные ограничения и выводы 7

3 Выбор и обоснование метода 7

3.1 Пространство признаков сложности–энтропии 7

3.2 Критика и исправление исходного конвейера 8

4 Методология и протокол оценки 8

4.1 Признаки кривых сложности–энтропии 8

4.2 Схемы линеаризации изображения 9

4.3 Протокол оценки и гипотезы 9

5 Математические свойства метода 9

6 Эксперименты и результаты 11

6.1 Данные 11

6.2 Эксперимент 1. Наличие сигнала 11

6.3 Эксперименты 2–3. Влияние параметров 11

6.4 Расширенное изучение d и τ 12

6.5 Внешняя валидация на CIFAKE 13

6.6 Контроль конфаунда источника 14

6.7 Эксперимент 4. Сравнение с базовыми методами 15

6.8 Эксперимент 5. Контролируемая инъекция артефактов 15

6.9 Эксперимент 6. Эмпирическая проверка предлагаемых расширений 16

6.10 Статистическая значимость и множественные сравнения 17

6.11 Амплитудно-зависимое и мультимасштабное расширения 17

6.12 Перенос на независимые датасеты 18

6.13 Оценка искажения относительно реальных изображений 19

7 Прикладной метод: ординальный детектор дублирования 20
7.1 Инвариантность к геометрии вставки 20
7.2 Калибровка порога решающего правила 21

8 Обсуждение 22

9 Математические расширения метода и новые идеи 22
9.1 Улучшения на основе литературы 23
9.2 Оригинальные идеи 23
9.3 Пересмотр метрик 24

10 Ограничения и направления будущей работы 24

11 Заключение 25

Список литературы 26

A Полная таблица параметрического перебора 29

1 Введение

Актуальность и значимость. Диффузионные модели лежат в основе творческого дизайна, научной визуализации и систем поддержки принятия решений, однако регулярно порождают ошибки генерации. Существующие протоколы оценки измеряют расхождение распределений с обучающими данными и слабо помогают количественно оценивать ошибки в конкретных новых генерациях. Для лёгких статистических дескрипторов особенно важна честная оценка: дешёвый метод легко выдать за работающий, измеряя его неподходящей метрикой на малой выборке. Работа показывает, как воспроизводимый протокол и параметрический анализ отделяют реальный сигнал от иллюзии, внося вклад в методологию оценки порождающих моделей. Исследование развивает и исправляет выпускную квалификационную работу бакалавра автора (1), в которой был предложен исходный конвейер на основе сложности–энтропии.

Объект и предмет. Объект исследования — методы оценки ошибок генерации диффузионных моделей на основе ординальных дескрипторов сложности–энтропии (CE). Предмет — влияние параметров таких методов (размерность вложения d, задержка τ, набор параметров Реньи, схема линеаризации 2D$\to$ 1D, двумерные шаблоны) на качество и статистическую значимость оценки.

Таксономия ошибок. Под «ошибкой генерации» объединяют разные явления, для CE существенно различные: (i) синтетичность — статистическое отличие сгенерированного изображения от реального; (ii) низкоуровневый артефакт — локальное искажение текстуры; (iii) структурное дублирование — повтор фрагмента; (iv) семантическая ошибка — нарушение смысла и несоответствие промпту. CE оперирует порядковой статистикой, поэтому сигнал естественно ожидать для (i)–(ii) и его отсутствие для (iv). Работа изучает оценку ошибок генерации и не претендует на обнаружение семантических галлюцинаций.

Цель. Установить, как параметры CE-методов влияют на оценку ошибок генерации, и определить, какие ошибки такие методы способны различать статистически значимо.

Задачи.

1. проанализировать современные методы оценки ошибок диффузионной генерации, выявив их допущения и ограничения;
2. заменить эвристическую метрику воспроизводимым протоколом (AUROC/AP, доверительные интервалы, тест значимости) и сформулировать проверяемые гипотезы;
3. систематически измерить влияние параметров метода на качество оценки;
4. проверить устойчивость выводов на независимом размеченном датасете и контролировать конфаунд источника данных.

Методы исследования. Ординальный (порядковый) анализ и кривые сложности–энтропии Реньи; статистическое обучение (логистическая регрессия); повторная стратифицированная кросс-валидация, бутстреп-доверительные интервалы, тест ДеЛонга и контроль доли ложных открытий; контролируемая инъекция артефактов с известной основной истиной.

Основной результат. CE — дешёвый интерпретируемый дескриптор синтетичности, качество которого управляется прежде всего задержкой и схемой линеаризации и не превосходит спектр Фурье; глобальная CE-статистика не даёт значимого сигнала для различения удачных и неудачных генераций, что объясняется её инвариантностью к структуросохраняющим искажениям. На основе нелокальных ординальных признаков построен лёгкий детектор дублирования, устойчивый к тоновой правке вставки.

Структура работы. Раздел 2 — обзор подходов; раздел 3 — выбор и исправление метода; раздел 4 — методология и протокол; раздел 5 — математические свойства; раздел 6 — эксперименты; раздел 7 — прикладной детектор дублирования; разделы 8–10 — обсуждение, расширения и ограничения; раздел 11 — заключение.

2 Обзор существующих подходов

2.1 Анализ интерполяции мод в латентном пространстве

Метод mode-interpolation отслеживает дисперсию траекторий обратной диффузии для выявления генераций вне носителя распределения (2). Дисперсия по последним K шагам:

$$\sigma^2 = \frac{1}{K}\sum_{k=1}^{K}\left\|x_{t_k} - \bar{x}\right\|_2^2, \qquad \bar{x} = \frac{1}{K}\sum_{k=1}^{K} x_{t_k}. \tag{2.1}$$

Ограничения: пороги зависят от модели, метрика глобальна, хранение всей траектории затратно.

2.2 Оценка через граф сцены и вопросно-ответную модель

Qin и др. преобразуют изображение в граф сцены и опрашивают языковую модель; рассогласование ответов и запроса указывает на галлюцинацию (3). Качество ограничено точностью распознавания и извлечения отношений, а время работы определяется инференсом LLM.

2.3 Локальная диффузионная декомпозиция

Kim и др. снижают структурные галлюцинации с помощью локальной диффузии, учитывающей области вне распределения (4). Однако качество OOD-масок и многократная выборка ограничивают практичность.

2.4 Анализ сложности–энтропии

Перестановочная энтропия. Для скалярного ряда $X = (x_1, \ldots, x_N)$, размерности вложения d, задержки τ и частот перестановок $P = \{p_i\}$ (5):

$$H_S(d,\tau) = -\sum_{i=1}^{d!} p_i \log p_i, \quad h_S = \frac{H_S}{\log d!} \in [0,1]. \tag{2.2}$$

Сложность Йенсена–Шеннона. При равномерном распределении P_u и $m_i = \frac{1}{2}(p_i + 1/d!)$:

$$D_{\mathrm{JS}}(P,P_u) = \tfrac{1}{2}\sum_i \Big[p_i \log\frac{p_i}{m_i} + \frac{1}{d!}\log\frac{1/d!}{m_i}\Big], \tag{2.3}$$

$$C_{\mathrm{JS}} = \frac{D_{\mathrm{JS}}(P,P_u)}{D_{\mathrm{JS}}^{\max}}\, h_S. \tag{2.4}$$

Точки (h_S, C_{JS}) образуют причинную плоскость сложности–энтропии (6).

Кривая сложности–энтропии Реньи. Замена энтропии Шеннона энтропией Реньи даёт семейство кривых, различающих хаотические, стохастические и периодические сигналы (7). Сложности этого подхода — чувствительность к (d,τ), факториальный рост $d!$ и инфляция энтропии шумом (8).

Двумерный и мультимасштабный ординальный анализ изображений. Перенос ординального анализа на изображения формализован: причинная плоскость сложности–энтропии обобщена на двумерные паттерны $D_x \times D_y$ (9), а её мультимасштабная версия использует пространственные задержки τ_x, τ_y (кратные шагу дискретизации) для сканирования текстур на разных масштабах и успешно различает текстуры Бродаца, фракталы и снимки Марса (10). Эти работы — прямое математическое основание нашего метода; наш базовый конвейер соответствует одномасштабному случаю ($\tau = 1$), а мультимасштабное обобщение мы относим к расширениям (раздел 9).

Амплитудно-зависимые варианты ординальной энтропии. Классическая перестановочная энтропия Бандта–Помпе отбрасывает амплитуду, учитывая лишь порядок. Ряд детерминированных, лёгких обобщений возвращает амплитудную информацию: взвешенная перестановочная энтропия (11), амплитудно-зависимая перестановочная энтропия (12) и дисперсионная энтропия на основе НФР (13). Все они сохраняют ключевые преимущества (детерминизм, линейная сложность) и являются естественными кандидатами на усиление CE-признаков.

Детекторы синтетических изображений. Параллельная линия работ показывает, что диффузионные генерации оставляют устойчивые частотные «отпечатки» (14; 15). Существенно, что у диффузионных изображений высокочастотные компоненты ниже, чем у реальных (тогда как у GAN — выше), а операции повышающей дискретизации порождают осевые локальные корреляции пикселей. Это напрямую объясняет наш результат (раздел 6.3): построчный растр, идущий вдоль осей, улавливает синтетичность лучше локально-связной кривой Гильберта. Энтропийный признак также используется напрямую: метод MLEP строит карты локальной энтропии по перемешанным мультимасштабным патчам как источниконезависимый признак, обобщающийся на 32 генератора (16), а самоподобие спектра предлагается как обобщаемый признак синтетичности (17). Общий вывод контекста: сигнал «реальное против синтетического» физически объясним, тогда как семантические галлюцинации такого простого статистического следа могут не оставлять.

2.5 Сравнительные ограничения и выводы

Ни один из методов не покрывает все типы галлюцинаций. Методы mode-interpolation и локальной диффузии требуют доступа к процессу выборки; SG-QA требует разметки запросов и дорог по времени. CE-подход уникален дешевизной и архитектурной независимостью, но именно поэтому требует особенно аккуратной проверки на статистическую значимость — чему и посвящена настоящая работа.

3 Выбор и обоснование метода

3.1 Пространство признаков сложности–энтропии

1. Архитектурная независимость. CE-дескрипторы оперируют порядковой статистикой отсчётов и не зависят от внутренних состояний модели.
2. Чувствительность к нерегулярной структуре. Комбинация нормированной перестановочной энтропии и статистической сложности разделяет стохастические, периодические и хаотические режимы.
3. Вычислительная эффективность. Требуется лишь подсчёт порядковых шаблонов; сложность линейна по длине сигнала.
4. Интерпретируемость. Двумерная плоскость CE даёт наглядную поверхность решения.

3.2 Критика и исправление исходного конвейера

Настоящая работа продолжает и исправляет выпускную квалификационную работу бакалавра автора (1); под «исходным конвейером» и «исходной метрикой» далее понимается реализация из этой работы. Исходная реализация преобразовывала изображение в одномерный сигнал, пропуская его через единственный свёрточный слой `nn.Conv2d`. Анализ кода выявил существенный дефект: свёртка была инициализирована случайно и не обучалась, причём новые случайные веса создавались при каждом вызове без фиксации зерна. В результате «сетка перебора» сравнивала один случайный проекционный шум с другим. Это объясняет, почему наблюдавшиеся в исходной работе «оценки разделения» имели порядок $0{,}004$ против $-0{,}001$ — то есть лежали в пределах статистического шума. В настоящей работе случайная свёртка полностью удалена: признаки вычисляются непосредственно из изображения (через явную схему линеаризации либо нативные двумерные порядковые шаблоны), а весь конвейер детерминирован.

Выводы по главе

Обзор показывает, что лёгкие ординальные дескрипторы дёшевы и архитектурно независимы, однако их применимость требует строгой проверки. Исходный конвейер содержал необучаемую случайную свёртку, дававшую шумовые результаты; она удалена, а оценка переведена на воспроизводимый протокол.

4 Методология и протокол оценки

Общая схема метода приведена на рис. 4.1: изображение переводится в оттенки серого и разворачивается в одномерный сигнал, по нему строятся порядковые шаблоны и кривая сложности–энтропии Реньи, а финальное решение даёт логистическая регрессия. Все шаги, кроме классификатора, детерминированы и линейны по числу пикселей.



Рис. 4.1: Схема метода оценки на основе сложности–энтропии (CE).

4.1 Признаки кривых сложности–энтропии

Порядковый шаблон окна — это перестановка, задающая относительный порядок его яркостей (рис. 4.2); признак изображения — частоты всех шаблонов. Поскольку шаблон зависит только от порядка, он инвариантен к монотонным тоновым преобразованиям (лемма 1). Для набора параметров Реньи $\alpha \in \mathscr{A} = \{0{,}0; 0{,}1; \ldots; 1{,}0\}$ ($|\mathscr{A}| = 10$) каждому сигналу сопоставляется вектор

$$\mathbf{f}(X) = [H_\alpha, C_\alpha]_{\alpha \in \mathscr{A}} \in \mathbb{R}^{2|\mathscr{A}|}, \tag{4.1}$$

где H_α — нормированная энтропия Реньи порядковых шаблонов, C_α — соответствующая статистическая сложность. Вычисления выполнены пакетом `ordpy` (18).

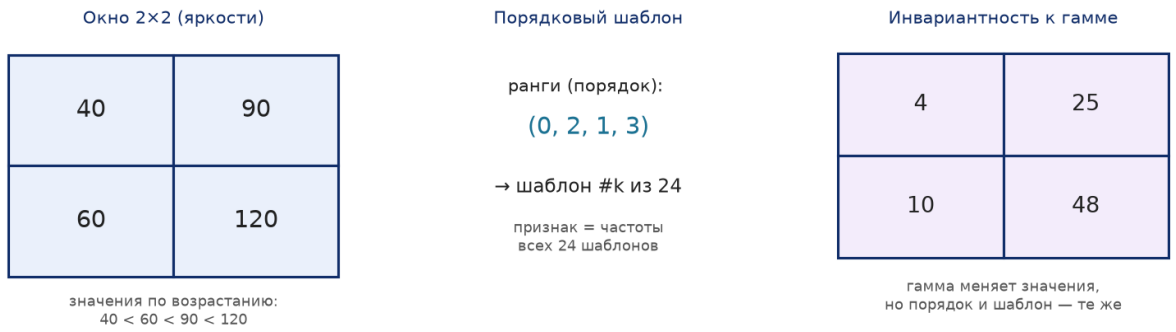


Рис. 4.2: Порядковый шаблон окна 2×2 и его инвариантность к монотонной тоновой правке: яркости меняются, относительный порядок и шаблон сохраняются.

4.2 Схемы линеаризации изображения

Изображение переводится в оттенки серого и масштабируется. Мы сравниваем пять схем обхода: построчный (`row`), постолбцовый (`col`), «змейкой» (`snake`), по антидиагоналям (`diag`) и вдоль кривой Гильберта (`hilbert`). Дополнительно используется нативный двумерный режим: порядковые шаблоны размера $d_x \times d_y$ строятся прямо по двумерной матрице яркостей, без линеаризации.

4.3 Протокол оценки и гипотезы

Поверх CE-признаков обучается логистическая регрессия со стандартизацией признаков (`scikit-learn` (19)). Качество оценивается повторной стратифицированной 5-кратной кросс-валидацией (5 повторов). Out-of-fold предсказание каждого объекта усредняется по повторам (одно значение на реальный объект), после чего для AUROC и средней точности (AP) строятся 95% бутстреп-доверительные интервалы (2000 ресэмплов) ресэмплингом реальных объектов. Усреднение по объекту здесь принципиально: наивное объединение всех повторов засчитывало бы каждый объект пятикратно и искусственно сужало доверительные интервалы. Этот протокол заменяет эвристическую метрику исходной работы (разделение средних вероятностей кластеров).

Мы раздельно проверяем две гипотезы:

H1. CE-признаки отличают реальные изображения от синтетических (real vs synthetic).

H2. CE-признаки отличают неудачные (галлюцинирующие) генерации от удачных (bad vs good).

Гипотеза считается подтверждённой, только если нижняя граница доверительного интервала AUROC строго превосходит 0,5.

5 Математические свойства метода

Три свойства ординальных дескрипторов формализуют и объясняют наблюдения разделов 6. Везде $X = (x_1, \ldots, x_N)$ — вещественный сигнал, а ординальный шаблон окна — перестановка, сортирующая его элементы; через P обозначена вероятностная мера ординальных шаблонов.

Лемма 1 (Инвариантность к монотонным преобразованиям). Пусть $g : \mathbb{R} \to \mathbb{R}$ строго возрастает. Тогда ординальный шаблон любого окна не меняется при поэлементном применении g, а потому распределение P, перестановочная энтропия и кривая сложности–энтропии инвариантны к замене $x_t \mapsto g(x_t)$.

Доказательство. Строго возрастающая g сохраняет порядок: $x_i < x_j \iff g(x_i) < g(x_j)$. Шаблон определён лишь относительным порядком значений, поэтому он совпадает для X и $g(X)$. Все величины, зависящие только от P, сохраняются. □

Следствие 1. CE-признаки инвариантны к яркости, контрасту, гамме и любой монотонной тоновой кривой. Спектральные и текстурно-гистограммные признаки этим свойством не обладают, что даёт CE устойчивость к различиям конвейеров обработки; этот эффект частично объясняет поведение при переносе (раздел 6.12).

Предложение 1 (Инвариантность к перестановке и слепота к дублированию). Мера P зависит лишь от мультимножества шаблонов окон и не зависит от их пространственного расположения. Пусть патч B (с распределением шаблонов внутренних окон P_B) копируется на целевую область T из m_T окон, исходное распределение которой P_T. Тогда изменение меры в полной вариации ограничено

$$\left\|P' - P\right\|_{\mathrm{TV}} \;\le\; \frac{m_T}{M}\left\|P_B - P_T\right\|_{\mathrm{TV}} \;+\; O\!\left(\frac{|\partial|}{M}\right), \tag{5.1}$$

где M — общее число окон, $|\partial|$ — число окон, пересекающих новую границу. Следовательно, любая величина, зависящая только от P (перестановочная энтропия, кривая Реньи, гистограмма переходов шаблонов), не может обнаружить дублирование, если копируемый и заменяемый фрагменты статистически близки ($P_B \approx P_T$): тогда оба слагаемых в (5.1) малы.

Доказательство. $P = \frac{1}{M}\sum_i \delta_{\pi_i}$ симметрична по индексу окна i. Копирование удаляет m_T внутренних окон области T (вклад $\frac{m_T}{M}P_T$) и добавляет m_T внутренних окон патча B (вклад $\frac{m_T}{M}P_B$); разность этих вкладов даёт первый член. Дополнительно изменяются лишь $O(|\partial|)$ окон, пересекающих границу, что даёт второй член. □

Следствие 2. Предложение 1 объясняет результат эксперимент 5: на структуросохраняющем артефакте `repeat`, где копируемый фрагмент берётся из того же изображения и потому статистически близок ($P_B \approx P_T$), гистограмма CE и сеть переходов Б1 остаются у случайности (раздел 6.8, 6.9). Дескриптор Б2 по построению использует пространственное расположение (сопоставление блоков по смещениям) и выходит за рамки этого ограничения.

Предложение 2 (Спектральная связь). Пусть X — стационарная гауссовская последовательность с нулевым средним и автоковариацией $\gamma(k)$. Для размерности вложения $d = 3$ и задержки τ введём приращения $\Delta_1 = x_{t+\tau} - x_t$, $\Delta_2 = x_{t+2\tau} - x_{t+\tau}$. Пара (Δ_1, Δ_2) гауссовская с корреляцией

$$r_\tau = \frac{2\gamma(\tau) - \gamma(0) - \gamma(2\tau)}{2\big(\gamma(0) - \gamma(\tau)\big)}. \tag{5.2}$$

Вероятность монотонного ординального шаблона (совпадение знаков Δ_1, Δ_2) по формуле Шеппарда равна $\frac{1}{2} + \frac{1}{\pi}\arcsin r_\tau$. Тем самым распределение шаблонов, перестановочная энтропия и кривая CE суть явные функции автоковариации на лагах τ и 2τ; по теореме Винера–Хинчина $\gamma(k) = \int_{-\pi}^{\pi} S(\omega)\cos(k\omega)\,d\omega$ они определяются спектром мощности S (20).

Доказательство. $\operatorname{Var}\Delta_1 = \operatorname{Var}\Delta_2 = 2(\gamma(0) - \gamma(\tau))$, а $\operatorname{Cov}(\Delta_1, \Delta_2) = 2\gamma(\tau) - \gamma(0) - \gamma(2\tau)$, откуда (5.2). Для двумерной гауссовской пары с нулевым средним и корреляцией r вероятность совпадения знаков равна $\frac{1}{2} + \frac{1}{\pi}\arcsin r$ (формула Шеппарда). □

Следствие 3. Задержка τ задаёт спектральные масштабы, на которых работает дескриптор. Для построчной развёртки изображения ширины W лаг $\tau = W$ отвечает ковариации вертикальных соседей, что объясняет наблюдаемый резонанс качества на $\tau = 256 = W$ (раздел 6.4).

Выводы по главе

Сформулированы две раздельные гипотезы и строгий протокол их проверки. Доказаны три свойства CE: инвариантность к монотонным преобразованиям, инвариантность к перестановке (с поправкой на различие распределений патчей) и связь со спектром через автоковариацию, объясняющая резонанс по задержке.

6 Эксперименты и результаты

6.1 Данные

Сбалансированный корпус из 100 изображений в трёх взаимоисключающих классах: Real (реальные фотографии, 33), Good (удачные диффузионные генерации, 32) и Bad (галлюцинирующие/неудачные генерации, 35). Класс Real взят из MS COCO (21) и FFHQ (22); Good — из подборок Midjourney (23), галереи DALL·E 3 (24), SDXL (25), Imagen (26), Mage (27) и Lexica (28); Bad — из таксономии артефактов Everypixel (29), тематической ветки r/StableDiffusion (30) и подборки Bored Panda (31). Задача H1 — Real против Good∪Bad; задача H2 — Bad против Good.

6.2 Эксперимент 1. Наличие сигнала

Таблица 6.1 приводит качество базовой конфигурации (`row`, $d = 5$, $\tau = 1$) и нативных 2D-шаблонов. Сигнал для H1 силён и значим (AUROC 0,857, ДИ строго выше 0,5); сигнал для H2 неотличим от случайного.

Таблица 6.1: Базовая оценка по двум задачам. H1 значимо превышает случайность, H2 — нет (доверительный интервал накрывает 0,5).

Задача	Конфигурация	n	AUROC [95% ДИ]	AP [95% ДИ]
H1 (real vs synthetic)	`row`, d=5, τ=1	100	0.858 [0.779, 0.927]	0.653 [0.507, 0.850]
H1 (real vs synthetic)	2D, d_x=d_y=2	100	0.767 [0.668, 0.854]	0.580 [0.438, 0.756]
H2 (bad vs good)	`row`, d=5, τ=1	67	0.446 [0.315, 0.591]	0.499 [0.376, 0.676]
H2 (bad vs good)	2D, d_x=d_y=2	67	0.393 [0.258, 0.539]	0.445 [0.339, 0.608]

6.3 Эксперименты 2–3. Влияние параметров

Перебор охватывает пять схем линеаризации × четыре значения $d \in \{3,4,5,6\}$ × две задержки $\tau \in \{1,2\}$, а также четыре конфигурации нативных 2D-шаблонов — всего 44 параметризации, каждая оценивалась по обеим задачам. Для задачи H1 качество существенно зависит от параметров (AUROC от 0,664 до 0,858), и зависимость интерпретируема:

- Задержка τ. $\tau = 1$ устойчиво превосходит $\tau = 2$ во всех схемах (в среднем 0,810 против 0,761); увеличение задержки разрушает локальные осевые корреляции, по которым и опознаётся синтетичность.
- Схема линеаризации. Горизонтальный растр (`snake` 0,844, `row` 0,842) превосходит `col` (0,799), `hilbert` (0,798) и `diag` (0,770). Контринтуитивно простой строчный обход обходит локально-связную кривую Гильберта: вероятно, артефакты повышающей дискретизации генераторов выровнены по осям.
- Размерность d. Влияет слабее; лучшие значения $d \in \{4,5,6\}$ при $\tau = 1$.

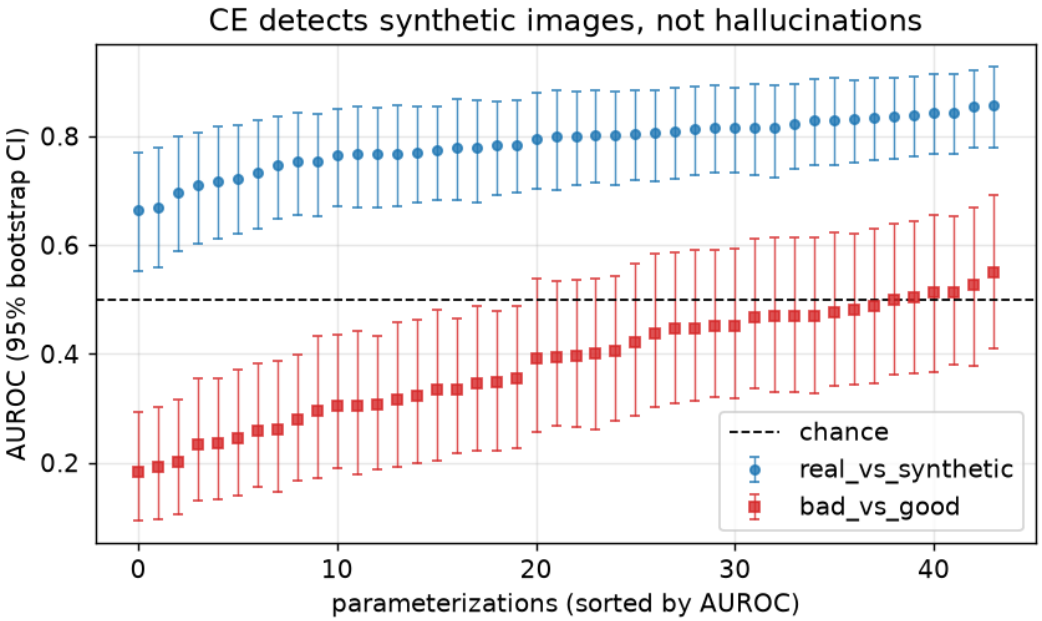


Рис. 6.1: AUROC всех 44 параметризаций, отсортированных по возрастанию, с 95% бутстреп-доверительными интервалами. Облако H1 (real vs synthetic) лежит выше линии случайности при всех настройках; облако H2 (bad vs good) прижато к 0,5. CE-дескрипторы различают синтетичность; для галлюцинаций сигнала нет.

- Нативные 2D-шаблоны. Конкурентоспособны (0,767–0,815), но не превосходят лучший одномерный растр.

Для задачи H2 ни одна конфигурация не даёт значимого сигнала: лучший AUROC лишь 0,549 с доверительным интервалом [0,411; 0,691], и у всех 44 конфигураций нижняя граница ДИ строго ниже 0,5; разброс 0,182–0,549 согласуется со случайным угадыванием. Это и есть статистически обоснованный отказ от гипотезы H2.

6.4 Расширенное изучение d и τ

Базовый перебор ограничивал $d \leq 6$ и $\tau \leq 2$. Здесь мы расширяем диапазоны на порядки: d до 60 и τ до 1024 (рис. 6.4). Это вскрывает два математических эффекта.

Потолок размерности вложения. Размерность d порождает $d!$ ординальных шаблонов. Пакет `ordpy` считает любое d быстро, поскольку хранит лишь наблюдённые шаблоны; однако при росте d отношение числа окон к числу шаблонов $N/d!$ стремится к нулю, каждое окно получает уникальный шаблон, нормированная энтропия вырождается (0,88 → 0,06), и различающая способность пропадает. Качество H1 держит плато до $d \approx 10$ (AUROC $\approx 0{,}85$), затем падает к случайности: d=20 → 0,69, d=30 → 0,54, d=50 → 0,47. При $d \geq 171$ величина $d!$ переполняет формат с плавающей точкой. Практический вывод: «брать d в сотни» бессмысленно по самой математике метода; рабочий диапазон $d \in [4, 8]$.

Резонанс задержки. По задержке качество H1 сперва спадает (τ=1 → 0,858, τ=16 → 0,54, τ=32 → 0,41), затем восстанавливается со вторичным пиком на τ=256 (0,81). Объяснение прямое: изображение линеаризовано построчно с шириной 256, поэтому задержка τ в ширину строки сэмплирует вертикальных соседей пикселя. Резонанс на $\tau = 256$ есть проявление структуры растра, и он связывает параметр τ с пространственной геометрией изображения.

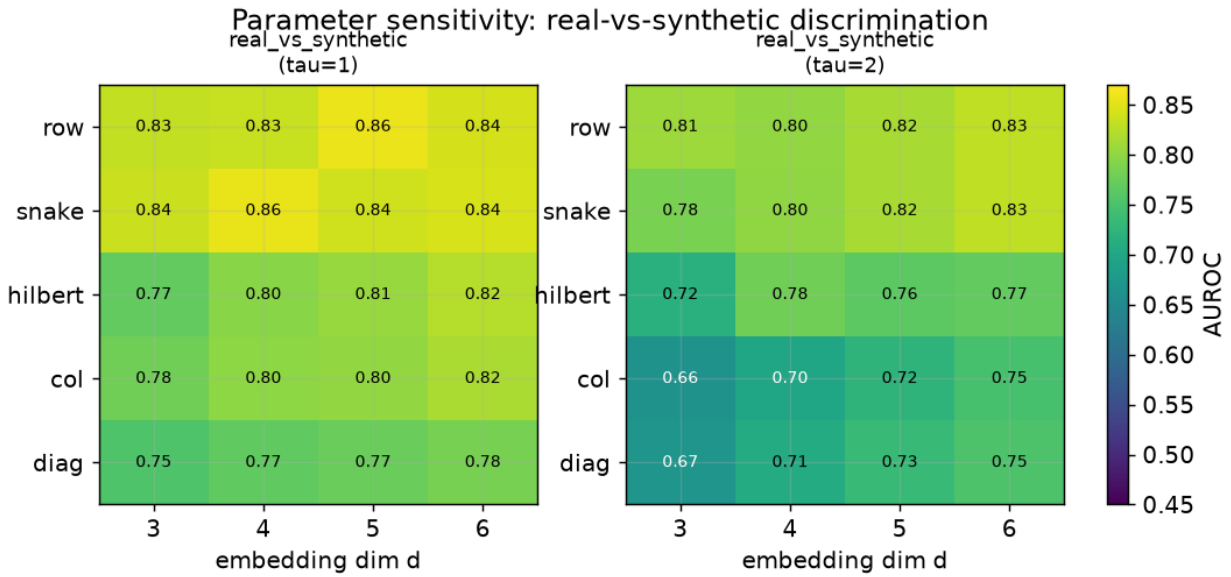


Рис. 6.2: Тепловые карты AUROC для задачи H1 (real vs synthetic) по схеме обхода (y) и размерности d (x) при $\tau = 1$ (слева) и $\tau = 2$ (справа). Видны доминирование $\tau = 1$ и преимущество горизонтального растра.

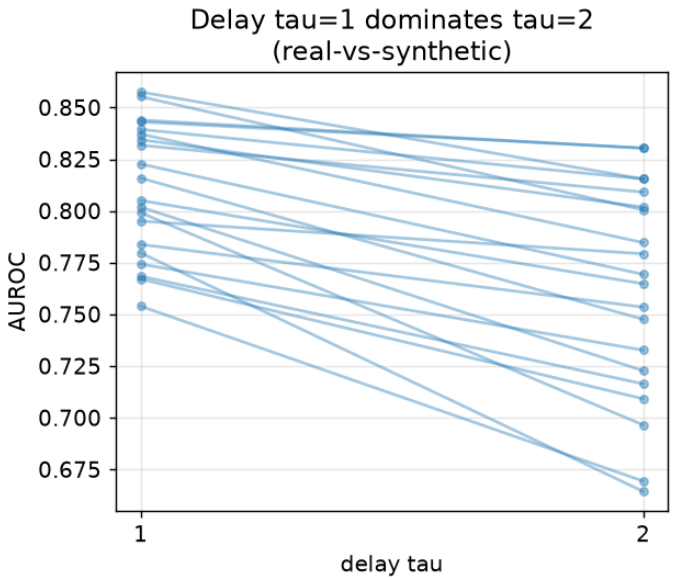


Рис. 6.3: Парный эффект задержки τ для H1: каждая линия — одна пара (схема, d). Переход τ=1 $\rightarrow$ τ=2 почти всегда снижает AUROC.

6.5 Внешняя валидация на CIFAKE

Чтобы исключить артефакт малой выборки, гипотеза H1 проверена на независимом датасете CIFAKE (15): реальные изображения CIFAR-10 против сгенерированных Stable Diffusion, разрешение 32×32 — иной генератор и иное разрешение. На сбалансированной выборке $n = 1200$ (600 real / 600 fake) качество приведено в таблице 6.2.

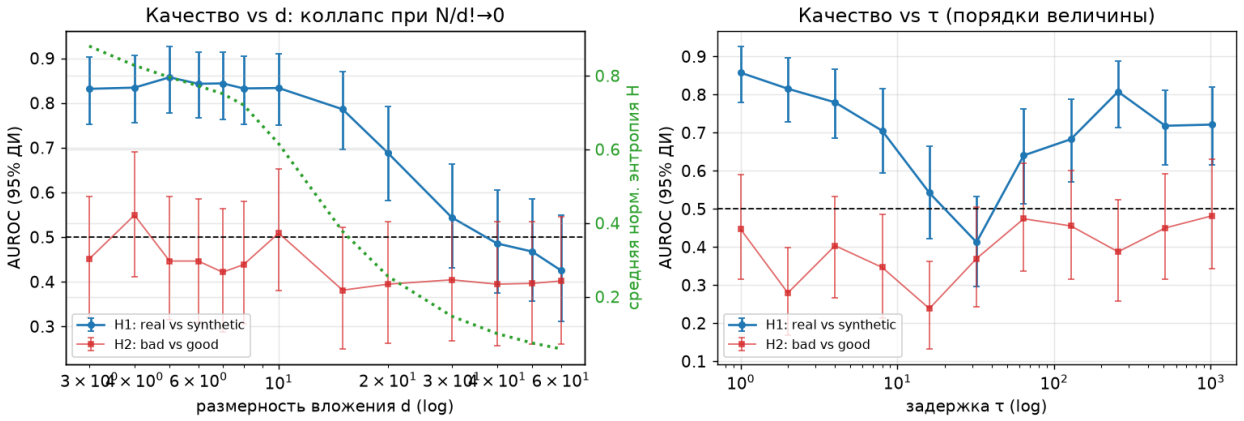


Рис. 6.4: Качество как функция размерности вложения d (слева; пунктир — средняя нормированная энтропия) и задержки τ (справа), логарифмическая ось. Слева виден коллапс при $N/d! \to 0$; справа — провал на $\tau \approx 32$ и резонансный пик на $\tau = 256$ (ширина изображения, сэмплирование вертикальных соседей).

Таблица 6.2: Валидация H1 на CIFAKE. Сигнал «реальное против синтетического» воспроизводится при узких доверительных интервалах; сохраняется и порядок параметров (растр превосходит 2D-шаблоны).

Конфигурация	n	AUROC [95% ДИ]	AP [95% ДИ]
`row`, d=5	1200	0.756 [0.727, 0.782]	0.731 [0.692, 0.771]
`row`, d=4	1200	0.747 [0.718, 0.773]	0.725 [0.687, 0.765]
2D, d_x=d_y=2	1200	0.706 [0.674, 0.733]	0.665 [0.621, 0.706]

Результат подтверждает H1 на данных другого генератора и разрешения, причём воспроизводится и качественная картина параметрической зависимости. Устойчивость показана внутри отдельных доменов; кросс-доменный перенос (раздел 6.12) остаётся ограниченным, поэтому вывод формулируется как наличие воспроизводимого внутридоменного сигнала синтетичности при отсутствии сигнала для семантических ошибок.

6.6 Контроль конфаунда источника

Собранный корпус неоднороден по происхождению: реальные изображения взяты из COCO/FFHQ, удачные генерации — из галерей, неудачные — из тематических подборок. Это порождает риск, что классификатор разделяет классы по следам источника (формат файла, разрешение, сжатие) вместо интересующей статистики. Мы проверяем это напрямую: обучаем тот же классификатор на признаках, составленных исключительно из метаданных файла (формат, ширина, высота, число мегапикселей, отношение сторон, размер в байтах). Распределения подтверждают неоднородность: медианное разрешение 0,29 Мп у реальных против 1,04 Мп у удачных; формат WEBP встречается у 14/32 удачных и почти отсутствует у реальных.

Метаданные дают $\mathrm{AUROC} = 0{,}938$ на H1 и 0,930 на H2 — выше, чем CE (таблица 6.3). Отсюда два следствия. Во-первых, внутридоменные числа H1 на собранном корпусе следует считать верхней оценкой, завышенной конфаундом; надёжной свободной от конфаунда проверкой H1 служит сбалансированный CIFAKE, где формат и разрешение классов совпадают. Во-вторых, ранее отмеченная маргинальная значимость объединённого набора на H2 (раздел 6.7) получает прямое объяснение: это сигнал источника,

Таблица 6.3: Контроль конфаунда. Одни лишь метаданные файла разделяют классы собранного корпуса лучше CE по обеим задачам. Поэтому внутридоменные числа H1 частично отражают происхождение данных наряду с синтетичностью; маргинальная значимость объединённого набора на H2 (раздел 6.7) объясняется тем же источником.

Признаки	задача	n	AUROC [95% ДИ]
только метаданные файла	H1 (real vs synthetic)	100	0.938 [0.860, 0.997]
CE	H1 (real vs synthetic)	100	0.858 [0.779, 0.927]
только метаданные файла	H2 (bad vs good)	67	0.930 [0.855, 0.985]
CE	H2 (bad vs good)	67	0.446 [0.315, 0.591]

а не ошибки генерации. Полный манифест корпуса (класс, формат, исходное разрешение, размер, хэш каждого файла) приведён в сопровождающем файле `paper/results/dataset_manifest.csv`.

6.7 Эксперимент 4. Сравнение с базовыми методами

Чтобы понять, уникален ли CE-сигнал, мы сравнили CE с дешёвыми интерпретируемыми признаками на том же протоколе: радиальный спектр мощности Фурье, текстурные дескрипторы Харалика (GLCM), гистограмма локальных бинарных шаблонов (LBP), элементарные пиксельные статистики, а также их объединение (таблица 6.4). Для задачи H1 CE не имеет статистически значимого преимущества: его AUROC 0,858 попадает в доверительные интервалы радиального спектра Фурье (0,845) и LBP (0,835). Иными словами, CE — лишь один из многих дешёвых текстурно-частотных дескрипторов синтетичности; выделенным методом он не является.

Для задачи H2 все одиночные признаки незначимы (ДИ накрывают 0,5). Единственное исключение — высокоразмерное объединение признаков (71 измерение, AUROC 0,651, ДИ [0,518; 0,779]). Этот результат мы объясняем конфаундом источника; обнаружением галлюцинаций он не является. Классы Good и Bad собраны с разных платформ (галереи против тематических подборок «провалов»), отличающихся сжатием, разрешением и постобработкой; на выборке $n = 67$ при 71 признаке высокоразмерный классификатор легко разделяет их по этим следам. Именно для устранения данного конфаунда поставлен контролируемый эксперимент 5.

Таблица 6.4: Сравнение CE с базовыми методами на едином протоколе. Для H1 CE статистически неотличим от спектра Фурье и LBP. Для H2 значим лишь высокоразмерный объединённый набор (†); его значимость объясняется конфаундом источника между классами Good и Bad.

Признаки	dim	H1: AUROC [95% ДИ]	H2: AUROC [95% ДИ]
FFT+GLCM+LBP (объедин.)	71	0.887 [0.817, 0.946]	0.651 [0.518, 0.779]†
CE (`row`, d=5)	20	0.858 [0.779, 0.927]	0.446 [0.315, 0.591]
FFT-спектр (радиальный)	25	0.845 [0.750, 0.928]	0.564 [0.423, 0.705]
LBP	10	0.835 [0.756, 0.905]	0.534 [0.400, 0.675]
GLCM/Харалик	36	0.815 [0.720, 0.898]	0.537 [0.384, 0.673]
пиксельные статистики	8	0.760 [0.651, 0.860]	0.535 [0.396, 0.675]

6.8 Эксперимент 5. Контролируемая инъекция артефактов

Чтобы измерить чувствительность CE к дефектам без конфаунда источника, мы вносили в реальные изображения локальные артефакты известной силы, получая согласованные пары «чистое/повреждённое», различающиеся только внесённым дефектом. Кросс-валидация группировалась по базовому изображению, бутстреп — по группам. Рассмотрены четыре типа: локальное размытие,

шумовой патч, геометрическое искажение (swirl) и копирование патча (`repeat`); сила варьировалась как доля площади (0,1; 0,2; 0,4). Результаты на рис. 6.5.

CE обнаруживает артефакты, меняющие локальную порядковую статистику (размытие: AUROC 0,557 → 0,826; шум: 0,535 → 0,833), и тем увереннее, чем сильнее дефект. При этом глобальная CE-гистограмма слепа к структуросохраняющему артефакту `repeat` (AUROC 0,529 → 0,457, незначимо даже при 40% площади); нелокальные ординальные признаки (Б2, раздел 6.9) частично восстанавливают этот сигнал. Дублирование объектов служит управляемым аналогом структурной ошибки. Вероятное объяснение отрицательного результата по H2 состоит в том, что многие семантические ошибки не обязаны менять локальную порядковую статистику, на которой основан CE. Дополнительно видно, что CE и спектр Фурье комплементарны: CE сильнее на размытии, спектр — на шуме; оба бессильны против `repeat`.

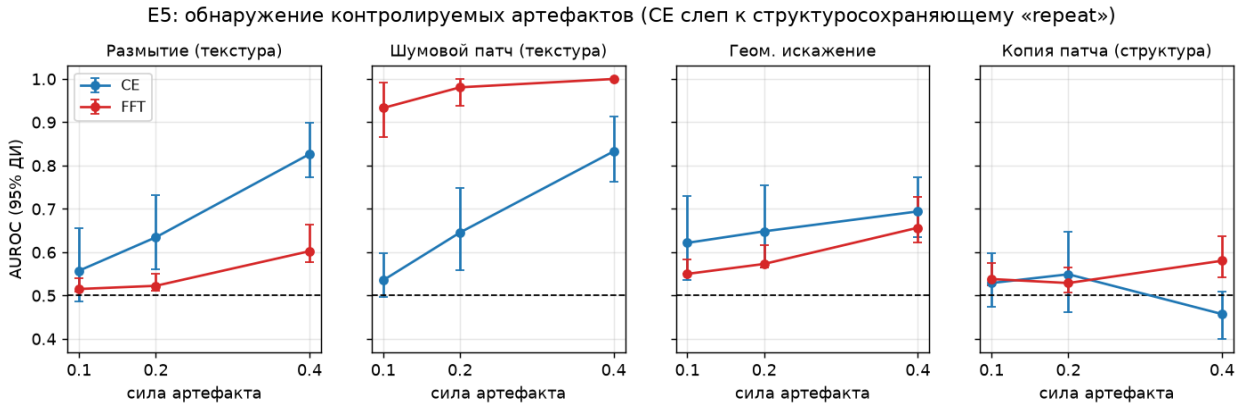


Рис. 6.5: Эксперимент 5: AUROC обнаружения контролируемых артефактов как функция силы дефекта (95% ДИ), CE против радиального спектра Фурье. CE растёт с силой текстурных дефектов (размытие, шум) и остаётся на уровне случайности для структуросохраняющей копии патча (правая панель) — аналога семантической галлюцинации.

6.9 Эксперимент 6. Эмпирическая проверка предлагаемых расширений

Четыре расширения из раздела 9 реализованы и проверены тем же протоколом; для структуросохраняющего случая использован контролируемый артефакт `repeat` из эксперимент 5 (группировка кросс-валидации по базовому изображению). Результаты в таблице 6.5.

Таблица 6.5: Эмпирическая проверка расширений. Б2 значимо реагирует на структуросохраняющее дублирование (нижняя граница ДИ 0,556 > 0,5), которое гистограмма CE (раздел 6.8, 0,46) и сеть переходов Б1 (0,52) не улавливают. Б3 даёт качество H1 уровня полного 20-мерного CE на 6 признаках. Значимость Б4 на H2 (†) воспроизводит конфаунд источника (60 признаков, $n = 67$).

Расширение	dim	H1 [95% ДИ]	H2 [95% ДИ]	эксперимент 5-`repeat` [95% ДИ]
Б1 сеть переходов	4	0.790 [0.698, 0.873]	0.493 [0.355, 0.631]	0.519 [0.485, 0.564]
Б2 автокорреляция	4	0.739 [0.636, 0.829]	0.606 [0.458, 0.743]	0.633 [0.556, 0.720]
Б3 геометрия кривой	6	0.839 [0.757, 0.911]	0.440 [0.304, 0.582]	—
Б4 анизотропия	60	0.804 [0.713, 0.882]	0.676 [0.546, 0.796]†	—

Два вывода имеют научную ценность по отдельности. Во-первых, Б1 подтверждает понимание ограничения: матрица переходов остаётся гистограммой пар шаблонов и инвариантна к сдвигу, поэтому к дублированию слепа так же, как обычная гистограмма. Во-вторых, Б2 опровергает неизбежность

этой слепоты: нелокальная ординальная автокорреляция значимо реагирует на дублирование, сохраняя детерминизм и лёгкость. Структуросохраняющие искажения становятся доступны оценке через нелокальные ординальные дескрипторы.

Развитие Б2. Базовый дескриптор Б2 дополнен офсетной автокорреляцией карты ординальных шаблонов: для набора смещений измеряется доля совпадающих индексов шаблонов сверх случайной коллизии, что задаёт детерминированный сигнал копирования. Зависимость качества от силы дублирования приведена на рис. 6.6. Объединённый дескриптор (блочный и офсетный) даёт лучший результат — AUROC $= 0{,}660$ при 40% площади — и монотонно растёт с размером дубля. Тест ДеЛонга (32; 33) подтверждает превышение случайности (односторонний $p = 0{,}028$); при этом прямое сравнение Б2 с сетью переходов Б1 пока не достигает значимости ($p = 0{,}21$) на 33 базовых изображениях, что указывает на потребность в большей выборке.

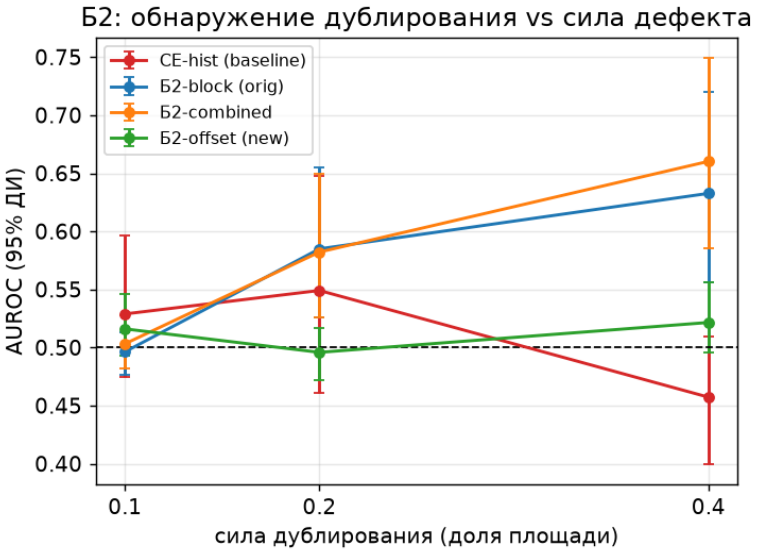


Рис. 6.6: Развитие Б2: AUROC обнаружения дублирования как функция силы дефекта. Блочный и объединённый дескрипторы растут с размером дубля; офсетный сам по себе слаб (текстурная автокорреляция фона), а гистограмма CE остаётся у случайности.

6.10 Статистическая значимость и множественные сравнения

Выводы подкреплены тестом ДеЛонга для AUROC и контролем доли ложных открытий. Для H1 различия CE и базовых методов не значимы: CE против спектра Фурье $p = 0{,}82$, против LBP $p = 0{,}48$, против объединённого набора $p = 0{,}46$ — что формально подтверждает отсутствие у CE преимущества. Для H2 ни одна из 44 конфигураций перебора не превышает случайность даже без поправки (односторонний DeLong-$p < 0{,}05$ у 0/44); после поправки Бенджамини–Хохберга (34) на уровне FDR 0,05 значимых также 0/44. Это переводит отказ от H2 из языка доверительных интервалов в формальный тест с контролем множественных сравнений.

6.11 Амплитудно-зависимое и мультимасштабное расширения

Реализованы два расширения из группы A (раздел 9). A1 — дисперсионная сложность–энтропия: амплитуда вводится через квантование сигнала по нормальной функции распределения (13), далее строится кривая Реньи по дисперсионным шаблонам. A2 — мультимасштабный двумерный CE: набор

пространственных задержек $\tau_x, \tau_y \in \{1,2,4,8,16\}$ по Zunino and Ribeiro (10). В пределах одного датасета ни одно расширение не улучшает H1 относительно базового CE (AUROC: A1 0,744, A2 0,776 против CE 0,859 на собранном корпусе); на низкоразрешённом CIFAKE A2 повышает качество до 0,824, что согласуется с зависимостью масштабных признаков от разрешения. Главная ценность расширений и базового CE проявляется в переносе на независимые данные (раздел 6.12).

Локальные карты сложности–энтропии с пулингом. Расширение A3 вычисляет CE по сетке патчей (64×64, шаг 32) и агрегирует покадровые (H,C) статистиками (среднее, минимум, максимум, перцентили). Идея в том, что редкий локальный дефект слабо смещает глобальную гистограмму, но заметно — максимум локальной сложности. На задачах H1/H2 пулинг не превосходит глобальный CE (H1 0,799 против 0,858; H2 0,446 без изменения). Однако на локализованном текстурном артефакте (шумовой патч, 20% площади) максимум-пулинг даёт решающее преимущество: AUROC $= 0{,}884$ [0,806; 0,957] против 0,594 у глобального CE; для размытия методы сопоставимы, а на структуросохраняющем дублировании оба остаются у случайности (0,50). Это подтверждает ожидание: локальные карты повышают чувствительность к локальным дефектам, оставаясь бессильными против семантических и структуросохраняющих ошибок.

6.12 Перенос на независимые датасеты

Практическая ценность лёгкого дескриптора состоит в переносимости: тяжёлые обучаемые детекторы синтетических изображений известны тем, что переобучаются под конкретный генератор и плохо обобщаются (14). Поскольку CE-подобные дескрипторы дают вектор признаков фиксированной размерности независимо от разрешения, перенос между датасетами возможен без переобучения. Мы обучаем классификатор на одном датасете и применяем его к другому без подстройки (zero-shot): собранный корпус (256 px) и CIFAKE (32 px, иной генератор). Результаты в таблице 6.6 и на рис. 6.7.

Таблица 6.6: Перенос между датасетами (AUROC). Тяжёлый высокоразмерный набор выигрывает в домене, однако переносится хуже всех: при обучении на CIFAKE и применении к собранному корпусу его качество падает до 0,175 (ниже случайности). Базовый CE удерживает 0,805 в этом направлении и остаётся самым переносимым.

Метод	dim	в домене local	в домене CIFAKE	L→C	C→L
CE	20	0.859	0.758	0.500	0.805
A1 дисперсия	11	0.744	0.751	0.503	0.565
A2 мультимасштаб	10	0.776	0.824	0.421	0.307
тяжёлый набор FFT+GLCM+LBP	71	0.891	0.942	0.614	0.175

Картина честная и содержит важные оговорки. Перенос труден для всех методов и асимметричен: направление L→C близко к случайности, поскольку собранный корпус мал и многогенераторен, а смена разрешения смещает распределение CE-признаков. При этом проявляется ясная закономерность: высокоразмерный обучаемый набор переобучается под датасет и в направлении C→L опускается до 0,175, тогда как лёгкий 20-мерный CE сохраняет 0,805 и деградирует наиболее мягко. Это подкрепляет тезис о переносимости лёгких ординальных дескрипторов: знание о статистике «реальное против синтетического» переносится у CE лучше, чем у тяжёлого отпечатка.

Контрольный эксперимент уточняет границы этого вывода. При приведении обоих датасетов к общему разрешению (32, 64, 128 px) перенос не восстанавливается систематически: качество C→L для CE колеблется в пределах 0,16–0,38 и зависит от выбранного разрешения, а понижение разрешения собранного корпуса само по себе ослабляет внутридоменный сигнал. Беспороговый скор Махаланобиса деградирует мягче обучаемого классификатора, оставаясь умеренным (0,55–0,63). Надёжный

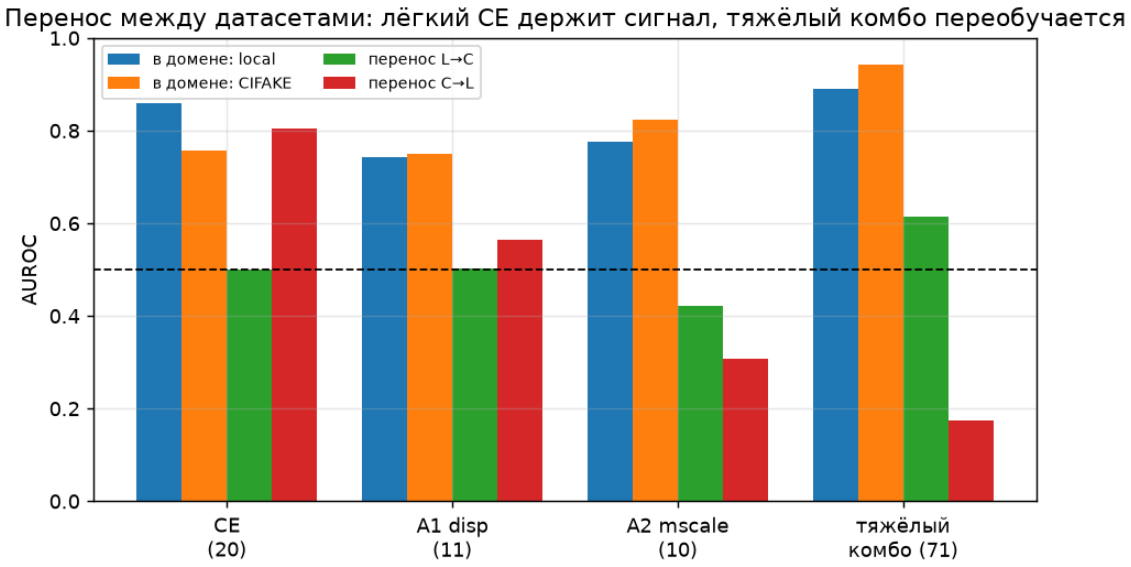


Рис. 6.7: Качество в домене и при zero-shot переносе. Тяжёлый набор даёт высшие столбцы в домене, но его перенос C→L (красный) опускается ниже случайности; лёгкий CE сохраняет наибольший перенос.

кросс-датасетный перенос между столь разными источниками (веб-фотографии против CIFAR, много генераторов против одного) остаётся открытой задачей; чистая проверка требует кросс-генераторного переноса при фиксированном разрешении.

6.13 Оценка искажения относительно реальных изображений

Сигнал H1 допускает беспороговую формулировку. По CE-признакам реальных изображений оценивается гауссовское многообразие (среднее и ковариация с регуляризацией Ледуа–Вольфа), а квадрат расстояния Махаланобиса до него служит непрерывной мерой искажения. Эта мера разделяет реальные и синтетические изображения почти как обучаемый классификатор: AUROC $= 0{,}815$, при медиане расстояния 1,3 для реальных против 12,6 и 12,8 для удачных и неудачных генераций (синтетика примерно в десять раз дальше от многообразия). При управляемом внесении искажений в реальные изображения мера растёт монотонно (размытие: $1 \to 563 \to 11846$; шум: $1 \to 14{,}6 \to 30$), что подтверждает её интерпретацию как меры искажения.

Дополнительный тест проясняет природу синтетического следа. Вдоль оси линейного дискриминанта (реальные против синтетических) размытые реальные изображения ($\sigma = 2$) смещаются на сторону синтетических (все 100% пересекают медиану реальных), тогда как зашумлённые остаются на стороне реальных. Низкочастотное искажение приближает реальное изображение к синтетическому, что согласуется с известным фактом о пониженных высоких частотах диффузионных генераций (14; 17).

Выводы по главе

Гипотеза H1 подтверждается внутри доменов, но контроль источника выявляет конфаунд, а CE не превосходит спектр Фурье. Гипотеза H2 отвергается на всех 44 конфигурациях; контролируемая инъекция артефактов вскрывает механизм — слепоту глобальной статистики к структуросохраняющему дублированию. Кросс-датасетный перенос остаётся ограниченным.

7 Прикладной метод: ординальный детектор дублирования

Единственный положительный сигнал по структурным дефектам (Б2) мы доводим до самостоятельного лёгкого детерминированного метода локализации копирования (copy-move). Метод полностью укладывается в ограничения < 1 ГБ ОЗУ и работает $\approx 0{,}45$ с на изображение 256×256.

Алгоритм. По изображению строится карта двумерных ординальных шаблонов P (индексы 2×2-окон). Каждый блок 10×10 карты P с достаточным разнообразием шаблонов хэшируется; одинаковые блоки, удалённые друг от друга, голосуют за вектор смещения между ними. Пик голосования даёт точное смещение копии δ^*; маска дубля строится из точных совпадений $P(p) = P(p + \delta^*)$ морфологической чисткой и отбором связных компонент. Всё детерминировано и линейно по числу пикселей.

Ключевое свойство. По лемме 1 ординальные шаблоны инвариантны к монотонной тоновой правке. Поэтому метод устойчив к типичному приёму маскировки подделки — изменению яркости или гаммы вставленного фрагмента, — на котором ломаются методы, основанные на интенсивностях. Мы сравниваем ординальный детектор с тем же конвейером, применённым к квантованным интенсивностям.

Таблица 7.1: Локализация и детекция copy-move (33 изображения, площадь дубля 8%). Без тоновой правки оба метода работают; при монотонной правке вставки интенсивностный детектор падает до случайности, а ординальный сохраняет F1 $\approx 0{,}87$ и AUROC $\approx 0{,}95$.

	ординальный		интенсивностный	
Условие	лок. F1	детекция AUROC	лок. F1	детекция AUROC
точная копия	0.906	0.966	0.843	0.855
копия + гамма 2,2	0.870	0.950	0.020	0.499
копия + гамма 0,45	0.863	0.965	0.017	0.500

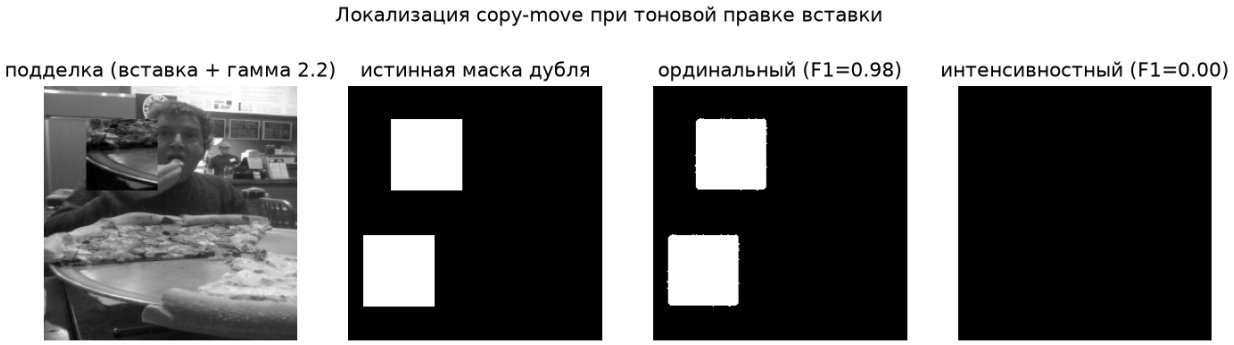


Рис. 7.1: Локализация при тоновой правке вставки (гамма 2,2). Ординальный детектор находит исходную и вставленную области; интенсивностный — нет.

Применимость и границы. Метод полезен как лёгкий детерминированный инструмент контроля качества и форензики: он локализует дублированные области и устойчив к тоновой маскировке, не требует обучения и переносится между изображениями без подстройки. Ограничения честны: он рассчитан на близкие к точным копии. Частичное снятие этого ограничения дано ниже.

7.1 Инвариантность к геометрии вставки

Точное хэширование осевых блоков не выдерживает геометрических преобразований вставки. Мы добавляем инвариантный вариант: вокруг каждого пикселя берутся $N = 8$ точек на концентрических

кольцах, вычисляются их ранги, и дескриптором служит канонический минимум по диэдральной группе (циклические сдвиги и отражение) последовательности рангов. Поворот изображения сдвигает кольцо циклически, отражение обращает его порядок, поэтому канонизация даёт инвариантность к отражению и повороту, а ранги сохраняют монотонную инвариантность (лемма 1); несколько радиусов дают терпимость к масштабу. Пиксели, чей дескриптор повторяется на удалении и образует связную область, помечаются как дубль.

Таблица 7.2: Детекция/локализация copy-move при геометрической правке вставки (детекция — AUROC). Кольцевой дескриптор добавляет инвариантность к отражению и повороту на 90° (детекция $\approx 0{,}86$, где блочный метод у случайности) ценой более грубой локализации. Произвольный поворот и масштаб остаются недостижимыми для точного ординального сопоставления.

	кольцевой (инвариантный)		блочный (только сдвиг)	
Геометрия вставки	лок. F1	детекция	лок. F1	детекция
сдвиг	0.381	0.856	0.857	0.950
отражение	0.375	0.856	0.015	0.516
поворот 90°	0.380	0.858	0.000	0.500
поворот 30°	0.024	0.459	0.000	0.500
масштаб 0,8	0.029	0.499	0.000	0.500

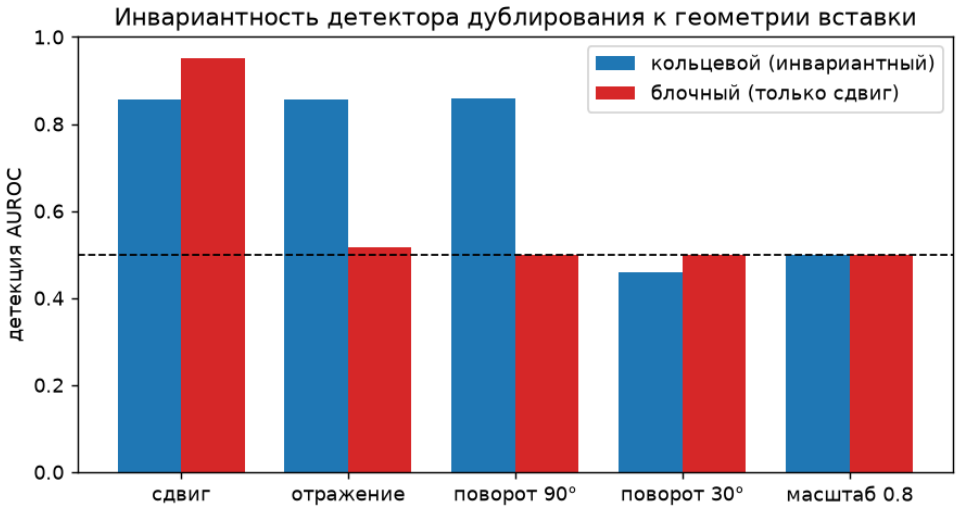


Рис. 7.2: Детекция дублирования при разной геометрии вставки. Кольцевой дескриптор устойчив к отражению и повороту 90°; оба метода теряют сигнал на произвольном повороте и масштабе.

Методы комплементарны: блочный даёт точную локализацию для сдвига и тоновой правки, кольцевой добавляет диэдральную инвариантность при более грубой локализации. Инвариантность к произвольному повороту и масштабу требует нечёткого (приближённого) сопоставления дескрипторов и оставлена развитию.

7.2 Калибровка порога решающего правила

Решающее правило детектора использует один порог по скору (доле площади совпадений). Чтобы избежать смещения отбора, базовые изображения разбиты на обучающую и отложенную части (60/40) без утечки: каждое базовое изображение целиком попадает в одну часть. Порог подбирается на обучающей части (по максимуму F_1 и по критерию Юдена), метрики рабочей точки приводятся на отложенной (таблица 7.3). Беспороговый AUROC на отложенной части составляет 0,959.

Таблица 7.3: Метрики рабочей точки на отложенной части (порог подобран на обучающей, разбиение по базовым изображениям). Калиброванный порог $\approx 0{,}07$–$0{,}10$ доли площади совпадений даёт $F_1 \approx 0{,}93$ и MCC $\approx 0{,}86$; критерий Юдена даёт нулевую долю ложных срабатываний при чуть меньшей полноте.

Порог (обучение)	точность	полнота	F_1	сбал. точность	MCC
макс. F_1 ($t = 0{,}068$)	0.929	0.929	0.929	0.929	0.857
критерий Юдена ($t = 0{,}097$)	1.000	0.857	0.923	0.929	0.866

Выводы по главе

На основе нелокальных ординальных признаков построен лёгкий детерминированный детектор-локализатор дублирования. Он устойчив к тоновой правке вставки (следствие монотонной инвариантности) и в кольцевом варианте — к отражению и повороту на 90 градусов; произвольный поворот и масштаб остаются ограничением.

8 Обсуждение

Результаты переворачивают исходную интерпретацию. То, что ранее подавалось как «детектор галлюцинаций» с «побочным эффектом» различения синтетики, на деле сводится к оценке синтетичности, а заявленной способности обнаруживать галлюцинации в данных нет. Это согласуется с физикой явления: реальные и синтетические изображения различаются устойчивыми частотно-текстурными характеристиками (14), которые порядковые шаблоны улавливают; семантические же галлюцинации (лишний палец, нечитаемый текст) не меняют глобальную порядковую статистику и потому невидимы для CE. эксперимент 5 (раздел 6.8) делает этот механизм наглядным: CE «видит» дефекты, искажающие локальную текстуру, но слеп к структуросохраняющему дублированию — именно к тому классу искажений, к которому относятся семантические галлюцинации.

Не менее важно, что сравнение с базовыми методами (эксперимент 4) показывает: на задаче H1 CE не превосходит тривиальный спектр Фурье. Следовательно, ценность CE состоит в дешевизне и интерпретируемости при сопоставимом качестве; претензия на уникальную диагностическую способность не подтверждается. Маргинальная значимость высокоразмерного объединённого набора на H2 объясняется конфаундом источника между классами; контролируемый эксперимент это подтверждает.

Параметрический анализ отвечает на вопрос, вынесенный в заголовок: качество CE-оценки определяется прежде всего задержкой ($\tau = 1$) и схемой линеаризации (горизонтальный растр), тогда как размерность вложения и переход к нативным 2D-шаблонам второстепенны. Эти зависимости воспроизводимы между двумя независимыми датасетами.

Наконец, выявленный дефект исходного конвейера (необучаемая случайная свёртка, раздел 3.2) — методологический урок: дешёвую эвристику легко принять за работающий метод, если оценивать её неподходящей метрикой на малой выборке. Строгий протокол с доверительными интервалами устраняет этот риск.

9 Математические расширения метода и новые идеи

Все предложения ниже сохраняют ключевые свойства метода — лёгкость, скорость, детерминизм: они развивают математику дескриптора и не вводят обучаемых параметров. Предложения разделены на (А) улучшения, опирающиеся на литературу, и (Б) оригинальные идеи, не встречавшиеся в данном

контексте. Оригинальные расширения реализованы и проверены эмпирически (раздел 6.9, таблица 6.5); ключевые наблюдения отмечены ниже по месту.

9.1 Улучшения на основе литературы

А1. Амплитудно-зависимые ординальные признаки. Классические шаблоны Бандта–Помпе отбрасывают амплитуду. Замена их взвешенной (11), амплитудно-зависимой (12) или дисперсионной (13) энтропией возвращает информацию о контрасте. Гипотеза: пересглаживание (low-pass) диффузионных изображений оставляет амплитудный след, который усилит H1; контрастные аномалии локальных галлюцинаций потенциально дают сигнал и для H2. Стоимость — та же $O(N)$.

А2. Мультимасштабный 2D-CE. Вслед за Zunino and Ribeiro (10) ввести пространственные задержки $\tau_x, \tau_y \in \{1, 2, 4, 8, \dots\}$ и конкатенировать CE-кривые по масштабам. Артефакты повышающей дискретизации локализованы по частоте/масштабу, поэтому мультимасштабный признак должен повышать и устойчивость H1, и кросс-генераторную обобщаемость, перекликаясь с самоподобием спектра (17).

А3. Локальные CE-карты с пулингом. Вместо одного глобального вектора вычислять CE по скользящим патчам, получая карту (H, C), и агрегировать её порядковыми статистиками (среднее, максимум, перцентили). Это детерминированный аналог идеи мультигранулярных энтропийных карт MLEP (16) без обучаемой CNN. Максимум-пулинг локальной сложности — прямой рычаг против локальных галлюцинаций, которые глобальная статистика усредняет (ограничение, выявленное в эксперимент 5).

9.2 Оригинальные идеи

Б1. Ординальные сети переходов для изображений (главная идея). Гистограмма ординальных шаблонов инвариантна к перестановке и сдвигу — и именно поэтому слепа к дублированию (механизм провала H2 и артефакта `repeat` в эксперимент 5). Предлагается перейти от гистограммы к графу переходов между соседними двумерными шаблонами и извлекать его инварианты (энтропия распределения рёбер, дисбаланс степеней, доля повторяющихся мотивов). Копия патча порождает аномальные повторяющиеся переходы, невидимые для гистограммы. Это принципиальная атака на структурную слепоту CE, оставающаяся детерминированной и линейной (подсчёт переходов). Эмпирически (эксперимент 6) этот вариант подтвердил ограничение: матрица переходов сама остаётся гистограммой, поэтому к дублированию слепа.

Б2. Нелокальная ординальная автокорреляция (детектор дублирования). Детерминированный дескриптор, измеряющий повторяемость блоков ординальных шаблонов по изображению (ординальный block-matching). Он прямо нацелен на структуросохраняющие артефакты дублирования (случай `repeat`), которые локальная CE-гистограмма принципиально не видит, — детектор повтора без обучения. Эмпирически (эксперимент 6) этот вариант значимо реагирует на дублирование ($\mathrm{AUROC} = 0{,}633$, нижняя граница ДИ выше 0,5), снимая ограничение, подтверждённое для Б1.

Б3. Геометрия кривой Реньи как признак. Кривые Реньи стохастических процессов имеют положительную кривизну у начала, а хаотических — отрицательную (7). Вместо подачи «сырых» (H_α, C_α) извлекать геометрические инварианты кривой (начальный наклон, кривизну, длину дуги) — компактные, интерпретируемые, детерминированные признаки меньшей размерности.

Б4. CE-анизотропия. Поскольку артефакты дискретизации выровнены по осям, разность CE, посчитанных вдоль горизонтального, вертикального и диагонального обходов, сама по себе является

признаком синтетичности. Наш перебор уже намекает на это (`row≠diag`); формализация зазора как одномерного дешёвого признака прямо мотивирована частотным механизмом из раздела 2.

9.3 Пересмотр метрик

Исходная эвристика score(Θ) заменена на AUROC/AP. Для полноты предлагается добавить: (i) пороговые метрики классификации — сбалансированную точность, F_1 и коэффициент Мэтьюса (MCC), устойчивый при дисбалансе; (ii) калибровку — ожидаемую калибровочную ошибку (ECE) и оценку Бриера, важные для риск-ориентированного использования; (iii) меры близости как безпороговый, неконтролируемый скоринг: расстояние Махаланобиса от точки до распределения CE-признаков реальных изображений, энергетическое расстояние или MMD между распределениями признаков классов. Последнее возвращает исходную идею «огибающей» реальных данных, но придаёт ей строгую вероятностную форму и сохраняет детерминизм.

10 Ограничения и направления будущей работы

- Сильные представления. Сравнение с дешёвыми признаками выполнено (раздел 6.7); следующий шаг — сопоставление с сильными обучаемыми представлениями (CLIP/DINOv2 + логистическая регрессия), чтобы оценить верхнюю границу качества различения синтетических изображений на тех же данных.
- Кросс-генераторная обобщаемость. Проверка на GenImage (множество генераторов) покажет, переносится ли сигнал между семействами моделей.
- Свободный от конфаунда корпус. Контроль источника (раздел 6.6) показал, что метаданные файла разделяют классы собранного корпуса; нужен сбор с единым пайплайном (одинаковые формат, разрешение, сжатие) и публикуемым datasheet, чтобы H1 измерял синтетичность, а не происхождение.
- Данные с семантическими галлюцинациями. эксперимент 5 моделирует структурные дефекты; нужен корпус с размеченными семантическими галлюцинациями (парные генерации одного генератора с известной ошибкой счёта объектов или несоответствием промпту), чтобы проверить H2 на целевом явлении.
- Выбор параметров без смещения отбора. Лучшая из 44 конфигураций выбрана на тех же данных, что создаёт риск selection bias; для итоговых чисел желателен вложенный (nested) CV либо заранее зафиксированный критерий выбора и отдельный тестовый набор.
- Сильные представления как верхняя граница. Сравнение с CLIP/DINOv2 и простыми CNN/ViT-признаками по тому же протоколу покажет цену интерпретируемости CE.
- Устойчивость к постобработке. Стресс-тест к JPEG/WebP-сжатию, передискретизации, кадрированию и удалению метаданных — для forensic-задач это часть предмета.
- Калибровка и риск-метрики. Для QA-применения нужны Brier, ECE, MCC и сбалансированная точность с анализом порогов.

Выводы по главе

Обсуждение связывает эмпирику с доказанными свойствами: CE измеряет статистику синтетичности и слеп к семантике; практическую ценность несут нелокальные ординальные признаки. Намечены направления развития и очерчены ограничения данных и протокола.

11 Заключение

В работе систематически изучено влияние параметров методов на основе сложности–энтропии на оценку ошибок генерации диффузионных моделей. Вместо эвристической метрики применён более строгий и воспроизводимый протокол (логистическая регрессия, повторная стратифицированная кросс-валидация, бутстреп-доверительные интервалы, тест ДеЛонга и контроль доли ложных открытий), а задача поставлена как раздельная проверка двух гипотез по явной таксономии ошибок. Основной вывод: CE-кривые служат дешёвым и интерпретируемым дескриптором синтетичности, который различает реальные и синтетические изображения внутри домена (AUROC до 0,858 на собранном корпусе и 0,756 на сбалансированном CIFAKE) и управляется прежде всего задержкой τ и схемой линеаризации, однако не превосходит тривиальный спектр Фурье. Контроль источника показал, что внутридоменные числа H1 частично завышены конфаундом данных, поэтому надёжной оценкой служит сбалансированный CIFAKE. Глобальная CE-статистика не решает задачу обнаружения семантических галлюцинаций: ни одна из 44 конфигураций не превышает случайность значимо (DeLong, FDR), а контролируемая инъекция артефактов показывает чувствительность к текстурным дефектам при слепоте к структуро-сохраняющему дублированию. Для структурных дефектов перспективны нелокальные ординальные признаки: на их основе построен прикладной детерминированный детектор-локализатор дублирования (copy-move), который локализует копии с $\mathrm{F1} \approx 0{,}9$ и, благодаря монотонной инвариантности (лемма 1), устойчив к тоновой маскировке вставки, где интенсивностные методы падают до случайности. Дополнительно выявлен и устранён методологический дефект исходного конвейера. Полученные результаты дают воспроизводимую основу для кросс-генераторной проверки и сбора свободного от конфаунда размеченного корпуса.

Список литературы

[1] Ф. К. Пахуров. Методы оценки ошибок генерации диффузионных моделей. Выпускная квалификационная работа бакалавра, НИУ ВШЭ, Факультет компьютерных наук, 2025. URL https://www.hse.ru/ba/data/students/diplomas/1047837923.

[2] Sumukh K Aithal, Pratyush Maini, Zachary C. Lipton, and J. Zico Kolter. Understanding hallucinations in diffusion models through mode interpolation. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, Advances in Neural Information Processing Systems, volume 37, pages 134614–134644. Curran Associates, Inc., 2024. URL https://proceedings.neurips.cc/paper_files/paper/2024/file/f29369d192b13184b65c6d2515474d78-Paper-Conference.pdf.

[3] Ziyuan Qin, Dongjie Cheng, Haoyu Wang, Huahui Yi, Yuting Shao, Zhiyuan Fan, Kang Li, and Qicheng Lao. Evaluating hallucination in text-to-image diffusion models with scene-graph based question-answering agent, 2024. URL https://arxiv.org/abs/2412.05722.

[4] Seunghoi Kim, Chen Jin, Tom Diethe, Matteo Figini, Henry F. J. Tregidgo, Asher Mullokandov, Philip Teare, and Daniel C. Alexander. Tackling structural hallucination in image translation with local diffusion. In Aleš Leonardis, Elisa Ricci, Stefan Roth, Olga Russakovsky, Torsten Sattler, and Gül Varol, editors, Computer Vision – ECCV 2024, pages 87–103, Cham, 2025. Springer Nature Switzerland. ISBN 978-3-031-73004-7.

[5] Christoph Bandt and Bernd Pompe. Permutation entropy: A natural complexity measure for time series. Physical Review Letters, 88(17):174102, 2002. doi:10.1103/PhysRevLett.88.174102.

[6] Haroldo V. Ribeiro, Max Jauregui, Luciano Zunino, and Ervin K. Lenzi. Characterizing time series via complexity-entropy curves. Phys. Rev. E, 95:062106, Jun 2017. doi:10.1103/PhysRevE.95.062106. URL https://link.aps.org/doi/10.1103/PhysRevE.95.062106.

[7] M. Jauregui, L. Zunino, E.K. Lenzi, R.S. Mendes, and H.V. Ribeiro. Characterization of time series via Rényi complexity–entropy curves. Physica A: Statistical Mechanics and its Applications, 498 (C):74–85, 2018. doi:10.1016/j.physa.2018.01.026. URL https://ideas.repec.org/a/eee/phsmap/v498y2018icp74-85.html.

[8] Kenichiro Cho and Takaya Miyano. Entropy test for complexity in chaotic time series. Nonlinear Theory and Its Applications, IEICE, 7(1):21–29, January 2016. doi:10.1587/nolta.7.21.

[9] Haroldo V. Ribeiro, Luciano Zunino, Ervin K. Lenzi, Perseu A. Santoro, and Renio S. Mendes. Complexity-entropy causality plane as a complexity measure for two-dimensional patterns. PLoS ONE, 7(8):e40689, 2012. doi:10.1371/journal.pone.0040689.

[10] Luciano Zunino and Haroldo V. Ribeiro. Discriminating image textures with the multiscale two-dimensional complexity-entropy causality plane. Chaos, Solitons & Fractals, 91:679–688, 2016. doi:10.1016/j.chaos.2016.09.005.

[11] Bilal Fadlallah, Badong Chen, Andreas Keil, and José Príncipe. Weighted-permutation entropy: A complexity measure for time series incorporating amplitude information. Physical Review E, 87(2): 022911, 2013. doi:10.1103/PhysRevE.87.022911.

[12] Hamed Azami and Javier Escudero. Amplitude-aware permutation entropy: Illustration in spike detection and signal segmentation. Computer Methods and Programs in Biomedicine, 128:40–51, 2016. doi:10.1016/j.cmpb.2016.02.008.

[13] Mostafa Rostaghi and Hamed Azami. Dispersion entropy: A measure for time-series analysis. IEEE Signal Processing Letters, 23(5):610–614, 2016. doi:10.1109/LSP.2016.2542881.

[14] Riccardo Corvi, Davide Cozzolino, Giada Zingarini, Giovanni Poggi, Koki Nagano, and Luisa Verdoliva. On the detection of synthetic images generated by diffusion models. In ICASSP, 2023. doi:10.1109/ICASSP49357.2023.10095167.

[15] Jordan J. Bird and Ahmad Lotfi. CIFAKE: Image classification and explainable identification of AI-generated synthetic images. IEEE Access, 12:15642–15650, 2024. doi:10.1109/ACCESS.2024.3356122.

[16] Lin Yuan, Xiaowan Li, Yan Zhang, Jiawei Zhang, Hongbo Li, and Xinbo Gao. MLEP: Multi-granularity local entropy patterns for universal AI-generated image detection, 2025. URL `https://arxiv.org/abs/2504.13726`.

[17] Chuangchuang Tan et al. Generalizable AI-generated image detection based on fractal self-similarity in the spectrum, 2025. URL `https://arxiv.org/abs/2503.08484`.

[18] Arthur A. B. Pessa and Haroldo V. Ribeiro. ordpy: A Python package for data analysis with permutation entropy and ordinal network methods. Chaos: An Interdisciplinary Journal of Nonlinear Science, 31(6): 063110, 2021. doi:10.1063/5.0049901.

[19] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12:2825–2830, 2011.

[20] Christoph Bandt and Faten Shiha. Order patterns in time series. Journal of Time Series Analysis, 28 (5):646–665, 2007. doi:10.1111/j.1467-9892.2007.00528.x.

[21] Tsung-Yi Lin, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays, Pietro Perona, Deva Ramanan, C. Lawrence Zitnick, and Piotr Dollár. Microsoft COCO: Common objects in context. In European Conference on Computer Vision, 2014.

[22] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019. doi:10.1109/CVPR.2019.00453. Introduces the FFHQ dataset (appendix).

[23] Midjourney. Midjourney `/explore` feed. `https://www.midjourney.com/explore`, 2025.

[24] OpenAI Community. Dall·e 3 community gallery. `https://community.openai.com/t/dalle3-gallery-for-2023-2024-share-your-creations/431189`, 2024.

[25] Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. SDXL: Improving latent diffusion models for high-resolution image synthesis. arXiv preprint arXiv:2307.01952, 2023.

[26] S. Saharia, W. Chan, H. Lee, J. Chang, S. Kolesnikov, et al. Imagen: Text-to-image diffusion models. `https://imagen.research.google`, 2022.

[27] Mage. Mage v3 image generator. `https://www.mage.space`, 2025.

[28] Lexica. Lexica.art search and generation engine. `https://lexica.art`, 2025.

[29] Everypixel Journal. Ai hallucination examples and why they happen. `https://journal.everypixel.com/ai-hallucination-examples`, 2024.

[30] r/StableDiffusion Community. "failures" mega-thread. `https://www.reddit.com/r/StableDiffusion/`, 2025.

[31] Bored Panda. 50 ai art fails that are both horrifying and hilarious. `https://www.boredpanda.com/ai-fails/`, 2025.

[32] Elizabeth R. DeLong, David M. DeLong, and Daniel L. Clarke-Pearson. Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. Biometrics, 44 (3):837–845, 1988. doi:10.2307/2531595.

[33] Xu Sun and Weichao Xu. Fast implementation of delong's algorithm for comparing the areas under correlated receiver operating characteristic curves. IEEE Signal Processing Letters, 21(11):1389–1393, 2014. doi:10.1109/LSP.2014.2337313.

[34] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. Journal of the Royal Statistical Society: Series B, 57(1):289–300, 1995.

A Полная таблица параметрического перебора

Полные результаты (44 параметризации $\times$ две задачи) с доверительными интервалами приведены в сопровождающем файле `paper/results/sweep.csv`. Ниже — сводка по схемам линеаризации для задачи H1 при $\tau = 1$.

Таблица A.1: Влияние схемы линеаризации на задачу H1 (real vs synthetic) при $\tau = 1$, агрегировано по $d \in \{3,4,5,6\}$.

Схема	среднее AUROC	min	max
`snake`	0.844	0.837	0.855
`row`	0.842	0.832	0.858
`col`	0.799	0.780	0.816
`hilbert`	0.798	0.768	0.823
`diag`	0.770	0.754	0.784