НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Магистерская программа «Финансовые технологии и анализ данных»

КУРСОВАЯ РАБОТА
(исследовательский проект)

на тему:

Исследование влияния параметров методов оценки ошибок генерации диффузионных моделей

Выполнил студент:

группа #МФТАД251, 1-й курс магистратуры Пахуров Фёдор Константинович

Принял научный руководитель:

Лукьянченко Пётр Павлович,
старший преподаватель,
Школа больших данных и информационного поиска

Москва 2026

Исследование влияния параметров методов оценки ошибок генерации диффузионных моделей

Курсовая работа (исследовательский проект)

Пахуров Фёдор Константинович
МФТАД251,
НИУ ВШЭ,
Москва, Россия
fpakhurov@gmail.com

Abstract

Диффузионные модели достигли высокого качества синтеза изображений, однако по-прежнему порождают «галлюцинации» — артефакты и фрагменты, расходящиеся с реальной семантикой или статистикой. В работе систематически изучается, как параметры лёгкого, архитектурно-независимого метода оценки на основе кривых сложности–энтропии Реньи (Rényi complexity–entropy, далее CE) влияют на его способность обнаруживать ошибки генерации. В отличие от исходной постановки, мы заменяем эвристическую метрику разделения на строгий протокол оценки: логистическую регрессию поверх CE-признаков, повторную стратифицированную кросс-валидацию и бутстреп-доверительные интервалы для AUROC и средней точности (AP). Мы формулируем две гипотезы и проверяем их раздельно: (H1) CE-признаки отличают реальные изображения от синтетических; (H2) CE-признаки отличают неудачные (галлюцинирующие) генерации от удачных. Перебор по схеме линеаризации 2D→1D, размерности вложения d, задержке τ и нативным двумерным порядковым шаблонам показывает, что гипотеза H1 уверенно подтверждается (AUROC до 0,858; нижняя граница доверительного интервала $0{,}779 > 0{,}5$), причём результат воспроизводится на независимом датасете CIFAKE (AUROC 0,756, $n = 1200$). При этом гипотеза H2 не подтверждается: ни одна из 44 проверенных конфигураций не превосходит случайное угадывание статистически значимо (у всех нижняя граница ДИ $< 0{,}5$; лучший AUROC 0,549, ДИ [0,411; 0,691]). Сравнение с базовыми методами (спектр Фурье, текстурные статистики Харалика, LBP) показывает, что CE не имеет преимущества над тривиальным радиальным спектром Фурье при детекции синтетичности. Контролируемая инъекция артефактов с известной основной истиной выявляет механизм: CE реагирует на дефекты, меняющие локальную порядковую статистику (размытие, шум), пропорционально их силе, но слеп к структуросохраняющему артефакту дублирования — ближайшему аналогу семантической галлюцинации, что и объясняет отрицательный результат по H2. Таким образом, CE-дескрипторы являются лёгким детектором синтетичности, а не галлюцинаций. Дополнительно вскрыта и устранена методологическая ошибка исходного конвейера — необучаемая случайно инициализированная свёртка, из-за которой ранее наблюдавшиеся «различия» были статистическим шумом.

Keywords: Диффузионные модели · Обнаружение галлюцинаций · Сложность–энтропия · Перестановочная энтропия · Кривые Реньи

Содержание

1 Цель и задачи 3

2 Постановка задачи 3

3 Актуальность 3

4 Обзор существующих подходов 3
- 4.1 Анализ интерполяции мод в латентном пространстве . . . 3
- 4.2 Оценка через граф сцены и вопросно-ответную модель . . . 4
- 4.3 Локальная диффузионная декомпозиция . . . 4
- 4.4 Анализ сложности–энтропии . . . 4
- 4.5 Сравнительные ограничения и выводы . . . 4

5 Выбор и обоснование метода 4
- 5.1 Пространство признаков сложности–энтропии . . . 4
- 5.2 Критика и исправление исходного конвейера . . . 5

6 Методология и протокол оценки 5
- 6.1 Признаки CE-кривых . . . 5
- 6.2 Схемы линеаризации 2D→1D . . . 5
- 6.3 Протокол оценки и гипотезы . . . 5

7 Эксперименты и результаты 5
- 7.1 Данные . . . 5
- 7.2 E1: наличие сигнала . . . 6
- 7.3 E2–E3: влияние параметров . . . 6
- 7.4 Внешняя валидация на CIFAKE . . . 8
- 7.5 E4: сравнение с базовыми методами . . . 8
- 7.6 E5: контролируемая инъекция артефактов . . . 8

8 Обсуждение 9

9 Ограничения и направления будущей работы 10

10 Заключение 10

Список литературы 11

A Полная таблица параметрического перебора 13

1 Цель и задачи

Цель. Установить, как параметры методов оценки на основе сложности–энтропии влияют на обнаружение ошибок генерации диффузионных моделей, и определить, какие из ошибок такие методы способны выявлять статистически значимо.

Задачи.

1. Обзор литературы. Проанализировать современные методы обнаружения галлюцинаций для диффузионных и смежных порождающих архитектур, выявив их допущения и ограничения.
2. Строгий протокол оценки. Заменить эвристические метрики разделения корректным протоколом машинного обучения с метриками AUROC/AP и бутстреп-доверительными интервалами; сформулировать проверяемые гипотезы.
3. Параметрическое исследование. Систематически измерить влияние схемы линеаризации изображения, размерности вложения d, задержки τ и нативных двумерных порядковых шаблонов на качество обнаружения.
4. Внешняя валидация. Проверить устойчивость выводов на независимом размеченном датасете, отличающемся генератором и разрешением.

2 Постановка задачи

Диффузионные модели достигают предельного качества генерации изображений и сигналов, но регулярно порождают галлюцинации — выходы, отклоняющиеся от реальной семантики или статистики. Существующие протоколы оценки преимущественно измеряют расхождение распределений с обучающими данными и слабо помогают обнаруживать галлюцинации в конкретных новых генерациях. Как следствие, отсутствуют надёжные лёгкие инструменты, помечающие подозрительный контент.

Метод на основе CE привлекателен своей дешевизной и интерпретируемостью, однако его поведение критически зависит от параметров (d, τ), схемы преобразования изображения в сигнал и набора параметров Реньи. Центральный вопрос данной работы: при каких параметрах и для какого рода ошибок CE-оценка даёт статистически значимый сигнал, а где наблюдаемые «различия» оказываются артефактом методологии? Мы намеренно ставим задачу как проверку гипотез, а не как демонстрацию работающего детектора, чтобы избежать ложноположительных выводов.

3 Актуальность

Диффузионные модели лежат в основе творческого дизайна, научной визуализации и систем поддержки принятия решений; необнаруженные галлюцинации подрывают доверие и распространяют дезинформацию. Индустрии нужны лёгкие конвейеры контроля качества, а академическому сообществу — понимание надёжности генерации. При этом для лёгких статистических индикаторов (к которым относится CE) особенно важна честная оценка: дешёвый метод легко выдать за работающий, измеряя его неподходящей метрикой на малой выборке. Настоящая работа показывает, как строгий протокол и параметрический анализ отделяют реальный сигнал от иллюзии, и тем самым вносит вклад в воспроизводимую методологию оценки порождающих моделей.

4 Обзор существующих подходов

4.1 Анализ интерполяции мод в латентном пространстве

Метод mode-interpolation отслеживает дисперсию траекторий обратной диффузии для выявления генераций вне носителя распределения[1]. Дисперсия по последним K шагам:

$$\sigma^2 = \frac{1}{K}\sum_{k=1}^{K}\left\|x_{t_k} - \bar{x}\right\|_2^2, \qquad \bar{x} = \frac{1}{K}\sum_{k=1}^{K} x_{t_k}. \tag{1}$$

Ограничения: пороги зависят от модели, метрика глобальна, хранение всей траектории затратно.

4.2 Оценка через граф сцены и вопросно-ответную модель

Qin и др. преобразуют изображение в граф сцены и опрашивают языковую модель; рассогласование ответов и запроса указывает на галлюцинацию [2]. Качество ограничено точностью распознавания и извлечения отношений, а время работы определяется инференсом LLM.

4.3 Локальная диффузионная декомпозиция

Kim и др. снижают структурные галлюцинации с помощью локальной диффузии, учитывающей области вне распределения [3]. Однако качество OOD-масок и многократная выборка ограничивают практичность.

4.4 Анализ сложности–энтропии

Перестановочная энтропия. Для скалярного ряда $X = (x_1, \dots, x_N)$, размерности вложения d, задержки τ и частот перестановок $P = \{p_i\}$ [4]:

$$H_S(d, \tau) = -\sum_{i=1}^{d!} p_i \log p_i, \quad h_S = \frac{H_S}{\log d!} \in [0, 1]. \tag{2}$$

Сложность Йенсена–Шеннона. При равномерном распределении P_u и $m_i = \frac{1}{2}(p_i + 1/d!)$:

$$D_{\mathrm{JS}}(P, P_u) = \tfrac{1}{2} \sum_i \Big[p_i \log \frac{p_i}{m_i} + \frac{1}{d!} \log \frac{1/d!}{m_i} \Big], \tag{3}$$

$$C_{\mathrm{JS}} = \frac{D_{\mathrm{JS}}(P, P_u)}{D_{\mathrm{JS}}^{\max}} \, h_S. \tag{4}$$

Точки (h_S, C_{JS}) образуют причинную плоскость сложности–энтропии [5].

Кривая сложности–энтропии Реньи. Замена энтропии Шеннона энтропией Реньи даёт семейство кривых, различающих хаотические, стохастические и периодические сигналы [6]. Сложности этого подхода — чувствительность к (d, τ), факториальный рост $d!$ и инфляция энтропии шумом [7].

Детекторы синтетических изображений. Параллельная линия работ показывает, что диффузионные генерации оставляют устойчивые частотные «отпечатки», по которым их можно отличать от реальных изображений [8,9]. Это важный контекст: сигнал «реальное против синтетического» физически объясним, тогда как семантические галлюцинации такого простого статистического следа могут не оставлять.

4.5 Сравнительные ограничения и выводы

Ни один из методов не покрывает все типы галлюцинаций. Методы mode-interpolation и локальной диффузии требуют доступа к процессу выборки; SG-QA требует разметки запросов и дорог по времени. CE-подход уникален дешевизной и архитектурной независимостью, но именно поэтому требует особенно аккуратной проверки на статистическую значимость — чему и посвящена настоящая работа.

5 Выбор и обоснование метода

5.1 Пространство признаков сложности–энтропии

1. Архитектурная независимость. CE-дескрипторы оперируют порядковой статистикой отсчётов и не зависят от внутренних состояний модели.
2. Чувствительность к нерегулярной структуре. Комбинация нормированной перестановочной энтропии и статистической сложности разделяет стохастические, периодические и хаотические режимы.
3. Вычислительная эффективность. Требуется лишь подсчёт порядковых шаблонов; сложность линейна по длине сигнала.
4. Интерпретируемость. Двумерная плоскость CE даёт наглядную поверхность решения.

5.2 Критика и исправление исходного конвейера

Исходная реализация преобразовывала изображение в одномерный сигнал, пропуская его через единственный свёрточный слой `nn.Conv2d`. Анализ кода выявил существенный дефект: свёртка была инициализирована случайно и не обучалась, причём новые случайные веса создавались при каждом вызове без фиксации зерна. В результате «сетка перебора» сравнивала один случайный проекционный шум с другим. Это объясняет, почему наблюдавшиеся в исходной работе «оценки разделения» имели порядок 0,004 против −0,001 — то есть лежали в пределах статистического шума. В настоящей работе случайная свёртка полностью удалена: признаки вычисляются непосредственно из изображения (через явную схему линеаризации либо нативные двумерные порядковые шаблоны), а весь конвейер детерминирован.

6 Методология и протокол оценки

6.1 Признаки CE-кривых

Для набора параметров Реньи $\alpha \in \mathcal{A} = \{0{,}0; 0{,}1; \ldots; 1{,}0\}$ ($|\mathcal{A}| = 10$) каждому сигналу сопоставляется вектор

$$\mathbf{f}(X) = [H_\alpha, C_\alpha]_{\alpha \in \mathcal{A}} \in \mathbb{R}^{2|\mathcal{A}|}, \tag{5}$$

где H_α — нормированная энтропия Реньи порядковых шаблонов, C_α — соответствующая статистическая сложность. Вычисления выполнены пакетом `ordpy`[10].

6.2 Схемы линеаризации 2D→1D

Изображение переводится в оттенки серого и масштабируется. Мы сравниваем пять схем обхода: построчный (`row`), постолбцовый (`col`), «змейкой» (`snake`), по антидиагоналям (`diag`) и вдоль кривой Гильберта (`hilbert`). Дополнительно используется нативный двумерный режим: порядковые шаблоны размера $d_x \times d_y$ строятся прямо по двумерной матрице яркостей, без линеаризации.

6.3 Протокол оценки и гипотезы

Поверх CE-признаков обучается логистическая регрессия со стандартизацией признаков (`scikit-learn`[11]). Качество оценивается повторной стратифицированной 5-кратной кросс-валидацией (5 повторов). Out-of-fold предсказание каждого объекта усредняется по повторам (одно значение на реальный объект), после чего для AUROC и средней точности (AP) строятся 95% бутстреп-доверительные интервалы (2000 ресэмплов) ресэмплингом реальных объектов. Усреднение по объекту, а не объединение всех повторов, принципиально: наивное объединение засчитывает каждый объект пятикратно и искусственно сужает доверительные интервалы. Этот протокол заменяет эвристическую метрику исходной работы (разделение средних вероятностей кластеров).

Мы раздельно проверяем две гипотезы:

- H1. CE-признаки отличают реальные изображения от синтетических (real vs synthetic).
- H2. CE-признаки отличают неудачные (галлюцинирующие) генерации от удачных (bad vs good).

Гипотеза считается подтверждённой, только если нижняя граница доверительного интервала AUROC строго превосходит 0,5.

7 Эксперименты и результаты

7.1 Данные

Сбалансированный корпус из 100 изображений в трёх взаимоисключающих классах: Real (реальные фотографии, 33), Good (удачные диффузионные генерации, 32) и Bad (галлюцинирующие/неудачные генерации, 35). Класс Real взят из MS COCO[12] и FFHQ[13]; Good — из подборок Midjourney[14], галереи DALL·E 3[15], SDXL[16], Imagen[17], Mage[18] и Lexica[19]; Bad — из таксономии артефактов Everypixel[20], тематической ветки r/StableDiffusion[21] и подборки Bored Panda[22]. Задача H1 — Real против Good∪Bad; задача H2 — Bad против Good.

7.2 E1: наличие сигнала

Таблица 1 приводит качество базовой конфигурации (`row`, $d = 5$, $\tau = 1$) и нативных 2D-шаблонов. Сигнал для H1 силён и значим (AUROC 0,857, ДИ строго выше 0,5); сигнал для H2 неотличим от случайного.

Задача	Конфигурация	n	AUROC [95% ДИ]	AP [95% ДИ]
H1 (real vs synthetic)	`row`, d=5, τ=1	100	0.858 [0.779, 0.927]	0.653 [0.507, 0.850]
H1 (real vs synthetic)	2D, d_x=d_y=2	100	0.767 [0.668, 0.854]	0.580 [0.438, 0.756]
H2 (bad vs good)	`row`, d=5, τ=1	67	0.446 [0.315, 0.591]	0.499 [0.376, 0.676]
H2 (bad vs good)	2D, d_x=d_y=2	67	0.393 [0.258, 0.539]	0.445 [0.339, 0.608]

Таблица 1: Базовая оценка по двум задачам. H1 значимо превышает случайность, H2 — нет (доверительный интервал накрывает 0,5).

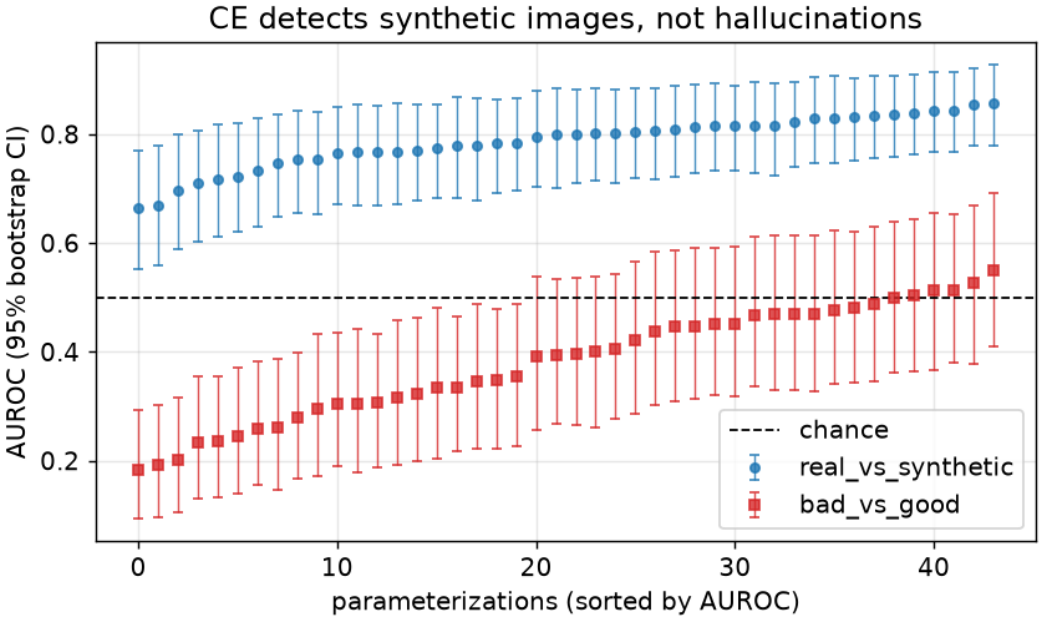


Рис. 1: AUROC всех 44 параметризаций, отсортированных по возрастанию, с 95% бутстреп-доверительными интервалами. Облако H1 (real vs synthetic) лежит выше линии случайности при всех настройках; облако H2 (bad vs good) прижато к 0,5. CE-дескрипторы обнаруживают синтетичность, но не галлюцинации.

7.3 E2–E3: влияние параметров

Перебор охватывает пять схем линеаризации × четыре значения $d \in \{3, 4, 5, 6\}$ × две задержки $\tau \in \{1, 2\}$, а также четыре конфигурации нативных 2D-шаблонов — всего 44 параметризации, каждая оценивалась по обеим задачам. Для задачи H1 качество существенно зависит от параметров (AUROC от 0,664 до 0,858), и зависимость интерпретируема:

- Задержка τ. $\tau = 1$ устойчиво превосходит $\tau = 2$ во всех схемах (в среднем 0,810 против 0,761); увеличение задержки разрушает локальные осевые корреляции, по которым и опознаётся синтетичность.
- Схема линеаризации. Горизонтальный растр (`snake` 0,844, `row` 0,842) превосходит `col` (0,799), `hilbert` (0,798) и `diag` (0,770). Контринтуитивно простой строчный обход обходит локально-связную кривую Гильберта: вероятно, артефакты повышающей дискретизации генераторов выровнены по осям.

- Размерность d. Влияет слабее; лучшие значения $d \in \{4, 5, 6\}$ при $\tau = 1$.
- Нативные 2D-шаблоны. Конкурентоспособны (0,767–0,815), но не превосходят лучший одномерный растр.

Для задачи H2 ни одна конфигурация не даёт значимого сигнала: лучший AUROC лишь 0,549 с доверительным интервалом [0,411; 0,691], и у всех 44 конфигураций нижняя граница ДИ строго ниже 0,5; разброс 0,182–0,549 согласуется со случайным угадыванием. Это и есть статистически обоснованный отказ от гипотезы H2.

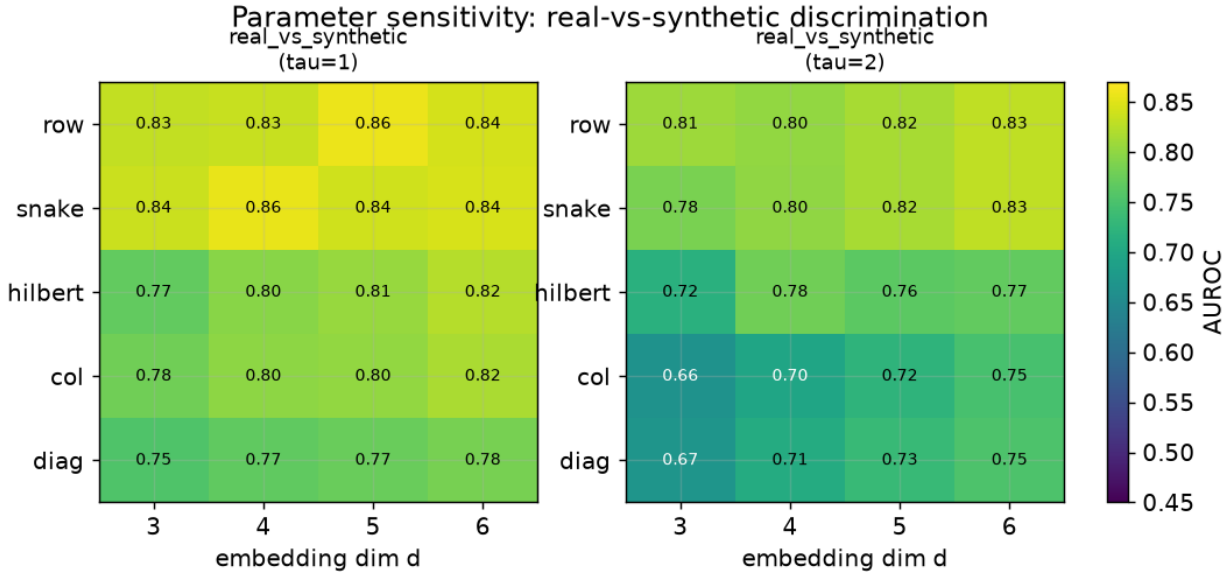


Рис. 2: Тепловые карты AUROC для задачи H1 (real vs synthetic) по схеме обхода (y) и размерности d (x) при $\tau = 1$ (слева) и $\tau = 2$ (справа). Видны доминирование $\tau = 1$ и преимущество горизонтального растра.

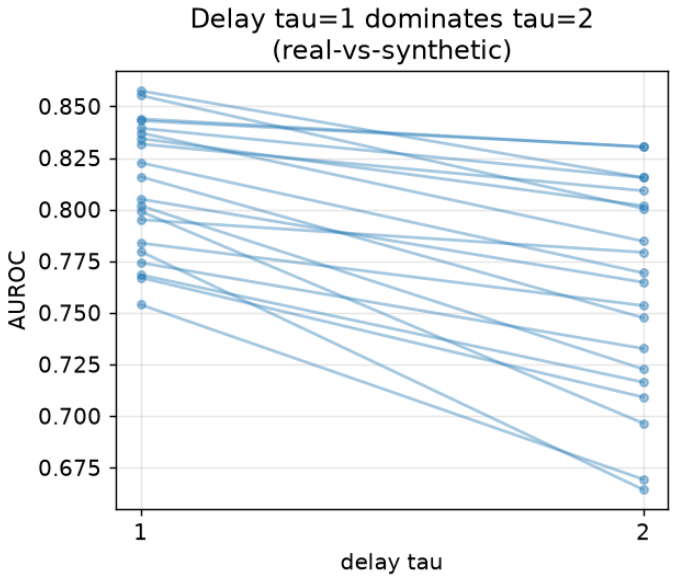


Рис. 3: Парный эффект задержки τ для H1: каждая линия — одна пара (схема, d). Переход τ=1 → τ=2 почти всегда снижает AUROC.

7.4 Внешняя валидация на CIFAKE

Чтобы исключить артефакт малой выборки, гипотеза H1 проверена на независимом датасете CIFAKE [9]: реальные изображения CIFAR-10 против сгенерированных Stable Diffusion, разрешение 32×32 — иной генератор и иное разрешение. На сбалансированной выборке $n = 1200$ (600 real / 600 fake) качество приведено в таблице 2.

Конфигурация	n	AUROC [95% ДИ]	AP [95% ДИ]
`row`, d=5	1200	0.756 [0.727, 0.782]	0.731 [0.692, 0.771]
`row`, d=4	1200	0.747 [0.718, 0.773]	0.725 [0.687, 0.765]
2D, d_x=d_y=2	1200	0.706 [0.674, 0.733]	0.665 [0.621, 0.706]

Таблица 2: Валидация H1 на CIFAKE. Сигнал «реальное против синтетического» воспроизводится при узких доверительных интервалах; сохраняется и порядок параметров (растр превосходит 2D-шаблоны).

Результат подтверждает H1 на данных другого генератора и разрешения, причём воспроизводится и качественная картина параметрической зависимости. Это усиливает основной вывод: CE-сигнал синтетичности устойчив, тогда как сигнала галлюцинаций нет.

7.5 E4: сравнение с базовыми методами

Чтобы понять, уникален ли CE-сигнал, мы сравнили CE с дешёвыми интерпретируемыми признаками на том же протоколе: радиальный спектр мощности Фурье, текстурные дескрипторы Харалика (GLCM), гистограмма локальных бинарных шаблонов (LBP), элементарные пиксельные статистики, а также их объединение (таблица 3). Для задачи H1 CE не имеет статистически значимого преимущества: его AUROC 0,858 попадает в доверительные интервалы радиального спектра Фурье (0,845) и LBP (0,835). Иными словами, CE — лишь один из многих дешёвых текстурно-частотных дескрипторов синтетичности, а не выделенный метод.

Для задачи H2 все одиночные признаки незначимы (ДИ накрывают 0,5). Единственное исключение — высокоразмерное объединение признаков (71 измерение, AUROC 0,651, ДИ [0,518; 0,779]). Однако этот результат мы интерпретируем как конфаунд источника, а не обнаружение галлюцинаций: классы Good и Bad собраны с разных платформ (галереи против тематических подборок «провалов»), отличающихся сжатием, разрешением и постобработкой; на выборке $n = 67$ при 71 признаке высокоразмерный классификатор легко разделяет их по этим следам. Именно для устранения данного конфаунда поставлен контролируемый эксперимент E5.

Признаки	dim	H1: AUROC [95% ДИ]	H2: AUROC [95% ДИ]
FFT+GLCM+LBP (объедин.)	71	0.887 [0.817, 0.946]	0.651 [0.518, 0.779]†
CE (`row`, d=5)	20	0.858 [0.779, 0.927]	0.446 [0.315, 0.591]
FFT-спектр (радиальный)	25	0.845 [0.750, 0.928]	0.564 [0.423, 0.705]
LBP	10	0.835 [0.756, 0.905]	0.534 [0.400, 0.675]
GLCM/Харалик	36	0.815 [0.720, 0.898]	0.537 [0.384, 0.673]
пиксельные статистики	8	0.760 [0.651, 0.860]	0.535 [0.396, 0.675]

Таблица 3: Сравнение CE с базовыми методами на едином протоколе. Для H1 CE статистически неотличим от спектра Фурье и LBP. Для H2 значим лишь высокоразмерный объединённый набор (†), что объясняется конфаундом источника между классами Good и Bad, а не обнаружением галлюцинаций.

7.6 E5: контролируемая инъекция артефактов

Чтобы измерить чувствительность CE к дефектам без конфаунда источника, мы вносили в реальные изображения локальные артефакты известной силы, получая согласованные пары «чистое/повреждённое», различающиеся только внесённым дефектом. Кросс-валидация группировалась по базовому изображению, бутстреп — по группам. Рассмотрены четыре типа: локальное размытие, шумовой патч, геометрическое искажение (swirl) и копирование патча (`repeat`); сила варьировалась как доля площади (0,1; 0,2; 0,4). Результаты на рис. 4.

CE обнаруживает артефакты, меняющие локальную порядковую статистику (размытие: AUROC 0,557 → 0,826; шум: 0,535 → 0,833), и тем увереннее, чем сильнее дефект. Однако CE полностью слеп к структуросохраняющему артефакту `repeat` (AUROC 0,529 → 0,457, незначимо даже при 40% площади). Между тем именно дублирование объектов — ближайший аналог семантической галлюцинации диффузионных моделей. Это механистически объясняет отрицательный результат по H2: реальные галлюцинации сохраняют локальную текстурную статистику, на которой основан CE. Дополнительно видно, что CE и спектр Фурье комплементарны: CE сильнее на размытии, спектр — на шуме; оба бессильны против `repeat`.

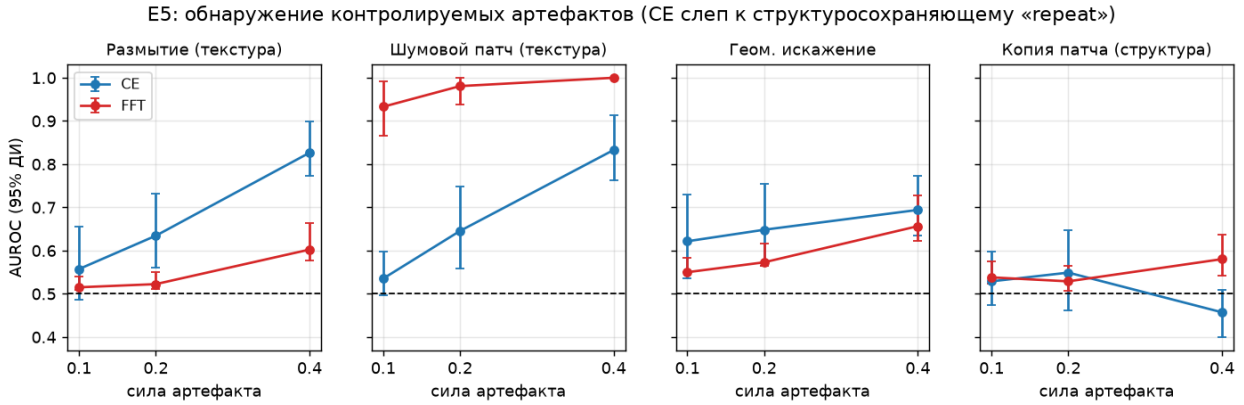


Рис. 4: E5: AUROC обнаружения контролируемых артефактов как функция силы дефекта (95% ДИ), CE против радиального спектра Фурье. CE растёт с силой текстурных дефектов (размытие, шум), но не реагирует на структуросохраняющую копию патча (правая панель) — аналог семантической галлюцинации.

8 Обсуждение

Результаты переворачивают исходную интерпретацию. То, что ранее подавалось как «детектор галлюцинаций» с «побочным эффектом» различения синтетики, на деле является детектором синтетичности, а заявленной способности обнаруживать галлюцинации в данных нет. Это согласуется с физикой явления: реальные и синтетические изображения различаются устойчивыми частотно-текстурными характеристиками[8], которые порядковые шаблоны улавливают; семантические же галлюцинации (лишний палец, нечитаемый текст) не меняют глобальную порядковую статистику и потому невидимы для CE. Эксперимент E5 (раздел 7.6) делает этот механизм наглядным: CE «видит» дефекты, искажающие локальную текстуру, но слеп к структуросохраняющему дублированию — именно к тому классу искажений, к которому относятся семантические галлюцинации.

Не менее важно, что сравнение с базовыми методами (E4) показывает: на задаче H1 CE не превосходит тривиальный спектр Фурье. Следовательно, ценность CE — не в рекордном качестве, а в дешевизне и интерпретируемости; претензия на уникальную диагностическую способность не подтверждается. Маргинальная значимость высокоразмерного объединённого набора на H2 объясняется конфаундом источника между классами, а не обнаружением галлюцинаций, что и подтверждает контролируемый эксперимент.

Параметрический анализ отвечает на вопрос, вынесенный в заголовок: качество CE-оценки определяется прежде всего задержкой ($\tau = 1$) и схемой линеаризации (горизонтальный растр), тогда как размерность вложения и переход к нативным 2D-шаблонам второстепенны. Эти зависимости воспроизводимы между двумя независимыми датасетами.

Наконец, выявленный дефект исходного конвейера (необучаемая случайная свёртка, раздел 5.2) — методологический урок: дешёвую эвристику легко принять за работающий метод, если оценивать её неподходящей метрикой на малой выборке. Строгий протокол с доверительными интервалами устраняет этот риск.

9 Ограничения и направления будущей работы

- Сильные представления. Сравнение с дешёвыми признаками выполнено (раздел 7.5); следующий шаг — сопоставление с сильными обучаемыми представлениями (CLIP/DINOv2 + логистическая регрессия), чтобы оценить верхнюю границу качества детекции синтетичности на тех же данных.
- Кросс-генераторная обобщаемость. Проверка на GenImage (множество генераторов) покажет, переносится ли сигнал между семействами моделей.
- Контролируемая инъекция артефактов. Внесение дозированных локальных дефектов в реальные изображения даёт основную истину по силе артефакта и позволяет напрямую измерить, при какой выраженности дефекта CE начинает на него реагировать.
- Локальные и многомасштабные дескрипторы. Глобальная CE-статистика может маскировать локальные галлюцинации; патч-уровневые карты CE — отдельное направление.
- Устойчивость к искажениям. JPEG/WebP-сжатие и передискретизация смещают точки в плоскости CE; нужен стресс-тест устойчивости детектора синтетичности.

10 Заключение

В работе систематически изучено влияние параметров методов оценки на основе сложности–энтропии на обнаружение ошибок генерации диффузионных моделей. Вместо эвристической метрики применён строгий протокол (логистическая регрессия, повторная стратифицированная кросс-валидация, бутстреп-доверительные интервалы), а задача поставлена как раздельная проверка двух гипотез. Установлено, что CE-признаки статистически значимо отличают реальные изображения от синтетических (AUROC до 0,858 на собранном корпусе и 0,756 на независимом CIFAKE), причём качество управляется прежде всего задержкой τ и схемой линеаризации; при этом CE не превосходит тривиальный спектр Фурье. Одновременно гипотеза о различении галлюцинирующих и удачных генераций не подтверждается: ни одна из 44 конфигураций не превосходит случайность значимо, а контролируемая инъекция артефактов вскрывает механизм — CE слеп к структуросохраняющим дефектам, к которым относятся семантические галлюцинации. Тем самым уточнена роль CE-дескрипторов — это лёгкий детектор синтетичности, а не галлюцинаций, — выявлен и устранён методологический дефект исходного конвейера, а сама оценка переведена на строгий протокол с честными доверительными интервалами. Полученные результаты дают воспроизводимую основу для дальнейшего расширения на большие датасеты и кросс-генераторную проверку.

Список литературы

1. Sumukh K Aithal, Pratyush Maini, Zachary C. Lipton, and J. Zico Kolter. Understanding hallucinations in diffusion models through mode interpolation. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, Advances in Neural Information Processing Systems, volume 37, pages 134614–134644. Curran Associates, Inc., 2024. URL https://proceedings.neurips.cc/paper_files/paper/2024/file/f29369d192b13184b65c6d2515474d78-Paper-Conference.pdf.
2. Ziyuan Qin, Dongjie Cheng, Haoyu Wang, Huahui Yi, Yuting Shao, Zhiyuan Fan, Kang Li, and Qicheng Lao. Evaluating hallucination in text-to-image diffusion models with scene-graph based question-answering agent, 2024. URL https://arxiv.org/abs/2412.05722.
3. Seunghoi Kim, Chen Jin, Tom Diethe, Matteo Figini, Henry F. J. Tregidgo, Asher Mullokandov, Philip Teare, and Daniel C. Alexander. Tackling structural hallucination in image translation with local diffusion. In Aleš Leonardis, Elisa Ricci, Stefan Roth, Olga Russakovsky, Torsten Sattler, and Gül Varol, editors, Computer Vision – ECCV 2024, pages 87–103, Cham, 2025. Springer Nature Switzerland. ISBN 978-3-031-73004-7.
4. Christoph Bandt and Bernd Pompe. Permutation entropy: A natural complexity measure for time series. Physical Review Letters, 88(17):174102, 2002. doi:10.1103/PhysRevLett.88.174102.
5. Haroldo V. Ribeiro, Max Jauregui, Luciano Zunino, and Ervin K. Lenzi. Characterizing time series via complexity-entropy curves. Phys. Rev. E, 95:062106, Jun 2017. doi:10.1103/PhysRevE.95.062106. URL https://link.aps.org/doi/10.1103/PhysRevE.95.062106.
6. M. Jauregui, L. Zunino, E.K. Lenzi, R.S. Mendes, and H.V. Ribeiro. Characterization of time series via Rényi complexity–entropy curves. Physica A: Statistical Mechanics and its Applications, 498 (C):74–85, 2018. doi:10.1016/j.physa.2018.01.026. URL https://ideas.repec.org/a/eee/phsmap/v498y2018icp74-85.html.
7. Kenichiro Cho and Takaya Miyano. Entropy test for complexity in chaotic time series. Nonlinear Theory and Its Applications, IEICE, 7(1):21–29, January 2016. doi:10.1587/nolta.7.21.
8. Riccardo Corvi, Davide Cozzolino, Giada Zingarini, Giovanni Poggi, Koki Nagano, and Luisa Verdoliva. On the detection of synthetic images generated by diffusion models. In ICASSP, 2023. doi:10.1109/ICASSP49357.2023.10095167.
9. Jordan J. Bird and Ahmad Lotfi. CIFAKE: Image classification and explainable identification of AI-generated synthetic images. IEEE Access, 12:15642–15650, 2024. doi:10.1109/ACCESS.2024.3356122.
10. Arthur A. B. Pessa and Haroldo V. Ribeiro. ordpy: A Python package for data analysis with permutation entropy and ordinal network methods. Chaos: An Interdisciplinary Journal of Nonlinear Science, 31(6): 063110, 2021. doi:10.1063/5.0049901.
11. F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12:2825–2830, 2011.
12. Tsung-Yi Lin, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays, Pietro Perona, Deva Ramanan, C. Lawrence Zitnick, and Piotr Dollár. Microsoft COCO: Common objects in context. In European Conference on Computer Vision, 2014.
13. Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. IEEE TPAMI, 2019. Appendix includes the FFHQ dataset.
14. Midjourney. Midjourney /explore feed. https://www.midjourney.com/explore, 2025.
15. OpenAI Community. Dall·e 3 community gallery. https://community.openai.com/t/dalle3-gallery-for-2023-2024-share-your-creations/431189, 2024.
16. Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. SDXL: Improving latent diffusion models for high-resolution image synthesis. arXiv preprint arXiv:2307.01952, 2023.
17. S. Saharia, W. Chan, H. Lee, J. Chang, S. Kolesnikov, et al. Imagen: Text-to-image diffusion models. https://imagen.research.google, 2022.
18. Mage. Mage v3 image generator. https://www.mage.space, 2025.
19. Lexica. Lexica.art search and generation engine. https://lexica.art, 2025.

20. Everypixel Journal. Ai hallucination examples and why they happen. https://journal.everypixel.com/ai-hallucination-examples, 2024.
21. r/StableDiffusion Community. “failures” mega-thread. https://www.reddit.com/r/StableDiffusion/, 2025.
22. Bored Panda. 50 ai art fails that are both horrifying and hilarious. https://www.boredpanda.com/ai-fails/, 2025.

A Полная таблица параметрического перебора

Полные результаты (44 параметризации $\times$ две задачи) с доверительными интервалами приведены в сопровождающем файле `paper/results/sweep.csv`. Ниже — сводка по схемам линеаризации для задачи H1 при $\tau = 1$.

Схема	среднее AUROC	min	max
`snake`	0.844	0.837	0.855
`row`	0.842	0.832	0.858
`col`	0.799	0.780	0.816
`hilbert`	0.798	0.768	0.823
`diag`	0.770	0.754	0.784

Таблица 4: Влияние схемы линеаризации на задачу H1 (real vs synthetic) при $\tau = 1$, агрегировано по $d \in \{3, 4, 5, 6\}$.