НИУ ВШЭ Факультет компьютерных наук
Научный руководитель: ст. преп. Лукьянченко П. П.

Москва, 2026

Исследование влияния параметров методов оценки ошибок генерации диффузионных моделей

Курсовая работа (исследовательский проект)

Пахуров Фёдор Константинович
группа МФТАД251



[СПИКЕР] Добрый день. Тема курсовой работы — исследование влияния параметров методов оценки ошибок генерации диффузионных моделей. Научный руководитель — Пётр Павлович Лукьянченко. Работа исследовательская: цель не построить детектор, а строго проверить границы применимости лёгкого статистического метода. [ПОЯСНЕНИЯ] Диффузионные модели — генеративные модели изображений (Stable Diffusion, Midjourney), синтезирующие картинку постепенным удалением шума. «Оценка», а не «обнаружение» — намеренно: данные показывают, что обнаружение семантических галлюцинаций методу недоступно, переобещать нельзя.

Проблема и постановка

Ошибки генерации бывают разной природы

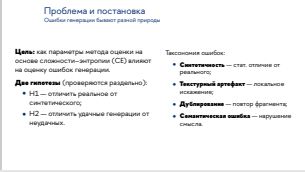
Цель: как параметры метода оценки на основе сложности–энтропии (CE) влияют на оценку ошибок генерации.

Две гипотезы (проверяются раздельно):

- H1 — отличить реальное от синтетического;
- H2 — отличить удачные генерации от неудачных.

Таксономия ошибок:

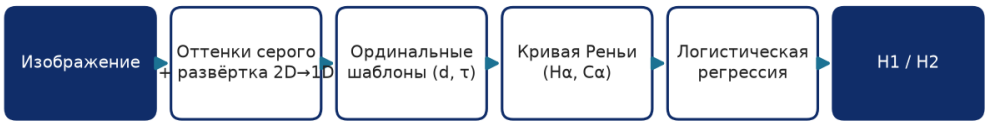
- **Синтетичность** — стат. отличие от реального;
- **Текстурный артефакт** — локальное искажение;
- **Дублирование** — повтор фрагмента;
- **Семантическая ошибка** — нарушение смысла.



[СПИКЕР] Ошибки очень разной природы, и я их сразу разделяю: синтетичность, текстурный артефакт, структурное дублирование, семантическая ошибка. Метод оценки — кривые сложности–энтропии Реньи, лёгкий детерминированный дескриптор на порядковой статистике. Чтобы избежать ложноположительных выводов, ставлю задачу как проверку двух гипотез: H1 — реальное против синтетического, H2 — удачные генерации против неудачных. [ПОЯСНЕНИЯ] CE: для сигнала считают распределение «порядковых шаблонов» (какой пиксель больше соседнего), по нему — энтропию (хаотичность) и статистическую сложность; точка (энтропия, сложность) описывает текстуру. «Детерминированный» — без обучения и случайности. Таксономия важна: для CE это разные задачи — текстурные дефекты меняют локальную статистику, семантические нет.

Метод и протокол

Строгая и воспроизводимая оценка



детерминированный, лёгкий (O(N)) дескриптор; обучается только финальный классификатор

Протокол оценки: логистическая регрессия + повторная кросс-валидация + бутстреп-ДИ + тест ДеЛонга + контроль FDR.

Исправлен дефект исходного конвейера (бакалаврская работа автора)

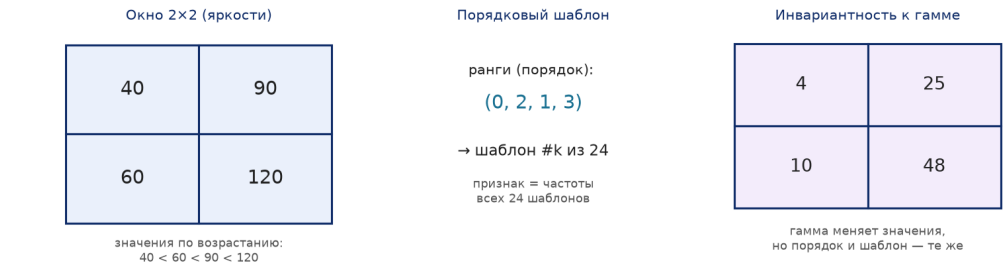
Необучаемая случайная свёртка давала «различия» на уровне шума; удалена — конвейер стал детерминированным.



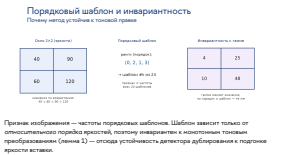
[СПИКЕР] Признак — точки кривой Реньи по порядковым шаблонам. Параметры: размерность вложения, задержка, схема развёртки, двумерные шаблоны. Вместо эвристики — строгий протокол: логистическая регрессия, повторная кросс-валидация, бутстреп-интервалы, тест ДеЛонга, контроль доли ложных открытий. Важно: эта работа продолжает и исправляет мою бакалаврскую ВКР — там стояла необучаемая случайная свёртка, дававшая шум; я её удалил. [ПОЯСНЕНИЯ] Схема: изображение оттенки серого и развёртка в одномерный сигнал порядковые шаблоны кривая Реньи (H ,C) классификатор. Кросс-валидация — обучение на одной части, проверка на другой. Бутстреп — пересэмплинг для доверительных интервалов. AUROC — вероятность, что «положительный» объект получит балл выше «отрицательного»; 0.5 = случайность. Тест ДеЛонга сравнивает два AUROC; FDR-поправка защищает от случайных находок.

Порядковый шаблон и инвариантность

Почему метод устойчив к тоновой правке



Признак изображения — частоты порядковых шаблонов. Шаблон зависит только от *относительного порядка* яркостей, поэтому инвариантен к монотонным тоновым преобразованиям (лемма 1) — отсюда устойчивость детектора дублирования к подгонке яркости вставки.



Признак изображения — частоты порядковых шаблонов. Шаблон зависит только от относительного порядка яркостей, поэтому инвариантен к монотонным тоновым преобразованиям (лемма 1) — отсюда устойчивость детектора дублирования к подгонке яркости вставки.

[СПИКЕР] Кратко о самом дескрипторе. Берём окно 2 на 2, смотрим относительный порядок яркостей — это и есть порядковый шаблон, один из 24. Признак изображения — частоты всех шаблонов. Ключевое свойство: шаблон зависит только от порядка, а не от абсолютных значений, поэтому изменение яркости или гаммы его не меняет. Это формализовано как лемма 1 и даёт устойчивость прикладного детектора к тоновой маскировке. [ПОЯСНЕНИЯ] На правой панели та же область после гамма-коррекции: значения другие (4, 25, 10, 48 вместо 40, 90, 60, 120), но порядок и шаблон совпадают. Именно это свойство монотонной инвариантности отличает ординальный подход от методов на абсолютных интенсивностях, которые ломаются при изменении яркости.

Главный результат: две гипотезы

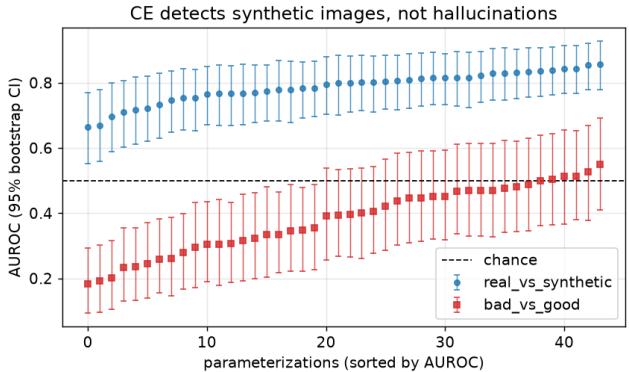
Сигнал есть для синтетичности, нет для галлюцинаций

H1 — реальное / синтетическое

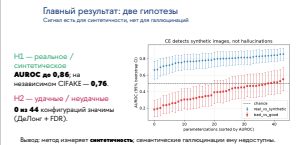
AUROC до 0,86; на независимом CIFAKE — **0,76**.

H2 — удачные / неудачные

0 из 44 конфигураций значимы (ДеЛонг + FDR).



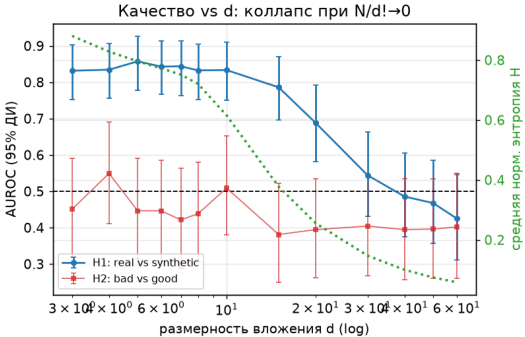
Вывод: метод измеряет **синтетичность**; семантические галлюцинации ему недоступны.

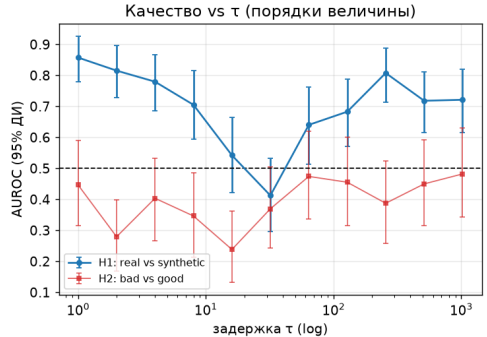


[СПИКЕР] Главный результат. По H1 сигнал есть: AUROC до 0.86 и 0.76 на независимом CIFAKE. По H2 сигнала нет: из 44 конфигураций ни одна не превышает случайность значимо — подтверждено ДеЛонгом с поправкой. Метод измеряет синтетичность; семантические галлюцинации недоступны. На графике синее облако (H1) выше случайности, красное (H2) прижато к 0.5. [ПОЯСНЕНИЯ] H1 = «real vs synthetic» (фото против сгенерированного). H2 = «bad vs good» (среди генераций — неудачные против удачных). CIFAKE — публичный датасет (реальные CIFAR-10 против Stable Diffusion), сбалансирован, поэтому надёжнее нашего корпуса. «0 из 44» — перебрали 44 набора параметров, ни один не значим для H2.

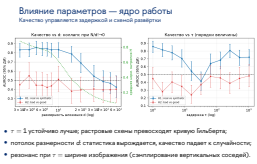
Влияние параметров — ядро работы

Качество управляется задержкой и схемой развёртки





- $\tau = 1$ устойчиво лучше; растровые схемы превосходят кривую Гильберта;
- потолок размерности d: статистика вырождается, качество падает к случайности;
- резонанс при $\tau =$ ширине изображения (сэмплирование вертикальных соседей).



[СПИКЕР] Параметрический анализ — ядро работы. Качество определяется задержкой и схемой развёртки: единичная задержка лучше, строчный растр обходит кривую Гильберта. По размерности — жёсткий потолок: число шаблонов растёт факториально, статистика вырождается, качество падает к случайности уже при нескольких десятках. Резонанс: качество восстанавливается, когда задержка равна ширине изображения — развёртка сэмплирует вертикальных соседей. [ПОЯСНЕНИЯ] Развёртка 2D 1D — превращение картинки в одномерный сигнал: построчно, змейкой, по кривой Гильберта. Гильберт сохраняет соседство, но растр эмпирически лучше: артефакты апскейлинга генераторов выровнены по осям. Для размерности d существует $d!$ шаблонов: при $d = 10$ это 3,6 млн — больше числа пикселей, статистика рассыпается.

Честность результата

Что именно измеряет метод

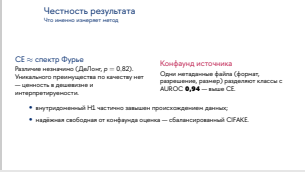
CE ≈ спектр Фурье

Различие незначимо (ДеЛонг, $p = 0{,}82$). Уникального преимущества по качеству нет — ценность в дешевизне и интерпретируемости.

Конфаунд источника

Одни метаданные файла (формат, разрешение, размер) разделяют классы с AUROC **0,94** — выше CE.

- внутридоменный H1 частично завышен происхождением данных;
- надёжная свободная от конфаунда оценка — сбалансированный CIFAKE.



[СПИКЕР] Важна честность результата. CE статистически неотличим от спектра Фурье — уникального преимущества нет, ценность в дешевизне и интерпретируемости. И конфаунд источника: одни метаданные файла — формат, разрешение, размер — разделяют классы с AUROC 0.94. Значит внутридоменный H1 частично завышен происхождением данных, доверять надо сбалансированному CIFAKE. [ПОЯСНЕНИЯ] Конфаунд — посторонняя переменная, коррелирующая с классом и «подсказывающая» ответ. Реальные снимки — COCO/FFHQ, удачные генерации — галереи, неудачные — подборки провалов; разный формат/разрешение/сжатие. Классификатор мог различать по «следу источника», а не по синтетичности. Я это измерил и зафиксировал. Спектр Фурье — разложение по частотам; у диффузии высокие частоты ниже, чем у реальных.

Математика и механизм

Доказанные свойства объясняют эмпирику

Лемма 1

Инвариантность к монотонным тоновым преобразованиям (ранги сохраняют порядок).

Предложение 1

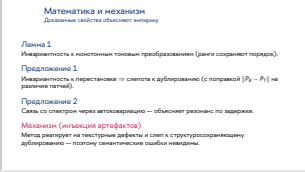
Инвариантность к перестановке $\Rightarrow$ слепота к дублированию (с поправкой $\|P_B - P_T\|$ на различие патчей).

Предложение 2

Связь со спектром через автоковариацию — объясняет резонанс по задержке.

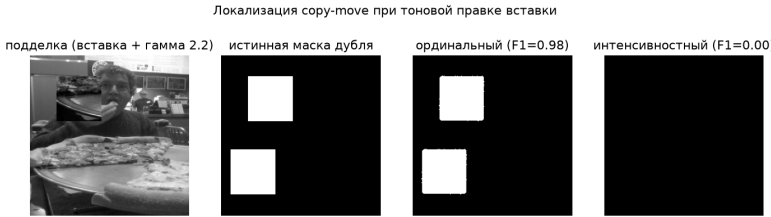
Механизм (инъекция артефактов)

Метод реагирует на текстурные дефекты и слеп к структуросохраняющему дублированию — поэтому семантические ошибки невидимы.



[СПИКЕР] Эмпирику подкрепляю тремя доказанными утверждениями: инвариантность к монотонным тоновым преобразованиям; инвариантность к перестановке, отсюда слепота к дублированию с поправкой на различие распределений патчей; связь со спектром через автоковариацию, объясняющая резонанс. Инъекция артефактов делает механизм наглядным: реакция на текстурные дефекты и слепота к структуросохраняющему дублированию — поэтому семантика невидима. [ПОЯСНЕНИЯ] Монотонное преобразование (яркость/гамма) сохраняет порядок яркостей, а шаблоны зависят только от порядка — отсюда устойчивость детектора дальше. Инвариантность к перестановке: гистограмма шаблонов не зависит от расположения, поэтому копию фрагмента не видит. Поправка означает: дублирование заметно, только если скопированный кусок статистически отличается от заменённого. Автоковариация + теорема Винера–Хинчина связывают порядковую статистику со спектром мощности.

Прикладной метод и выводы



- лёгкий детерминированный детектор-локализатор дублирования: **F1 0,93**, MCC 0,86;
- устойчив к тоновой правке вставки (интенсивностный метод падает к случайности); инвариантен к отражению и повороту 90°.

Итог

CE — дешёвый интерпретируемый дескриптор синтетичности и локальных дефектов; семантические галлюцинации он не решает. Вклад: честный негатив с доказательствами, параметрический анализ и применимый детектор дублирования.



[СПИКЕР] Из единственного положительного сигнала довёл до конца прикладной метод — лёгкий детерминированный детектор-локализатор дублирования. С калиброванным порогом — F1 0.93 и MCC 0.86 на отложенной выборке. Преимущество выведено из доказанной инвариантности: устойчив к подгонке яркости вставки, где интенсивностные методы падают к случайности; кольцевой вариант добавляет устойчивость к отражению и повороту 90 градусов. Итог: CE — дешёвый интерпретируемый дескриптор синтетичности и локальных дефектов; семантические галлюцинации не решает. Вклад — честный отрицательный результат с математикой, параметрический анализ и применимый детектор дублирования. Спасибо за внимание, готов к вопросам. [ПОЯСНЕНИЯ] Copy-move — подделка, когда фрагмент копируется внутри того же изображения. F1 — баланс точности и полноты; MCC — коэффициент Мэтьюса, устойчив при дисбалансе классов. «Калиброванный порог» подобран на обучающей части и проверен на отложенной без утечки. Метод полезен в forensics: лёгкий, без обучения, переносится между изображениями, устойчив к маскировке яркостью.