НИУ ВШЭ Факультет компьютерных наук
Научный руководитель: ст. преп. Лукьянченко П. П.

Москва, 2026

Исследование влияния параметров методов оценки ошибок генерации диффузионных моделей

Курсовая работа (исследовательский проект)

Пахуров Фёдор Константинович
группа МФТАД251

Оценка ошибок диффузии



[СПИКЕР] Добрый день. Тема курсовой работы — исследование влияния параметров методов оценки ошибок генерации диффузионных моделей. Научный руководитель — Пётр Павлович Лукьянченко. Работа исследовательская: цель не построить детектор, а строго проверить границы применимости лёгкого статистического метода. [ПОЯСНЕНИЯ] Диффузионные модели — генеративные модели изображений (Stable Diffusion, Midjourney), синтезирующие картинку постепенным удалением шума. «Оценка», а не «обнаружение» — намеренно: данные показывают, что обнаружение семантических галлюцинаций методу недоступно, переобещать нельзя.

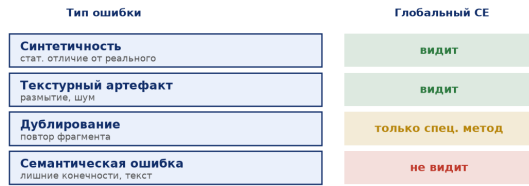
Задача

Оценка ошибок генерации диффузионных моделей

Цель: как параметры лёгкого дескриптора на основе сложности–энтропии (CE) влияют на оценку ошибок генерации.

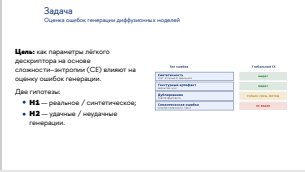
Две гипотезы:

- **H1** — реальное / синтетическое;
- **H2** — удачные / неудачные генерации.



Оценка ошибок диффузии

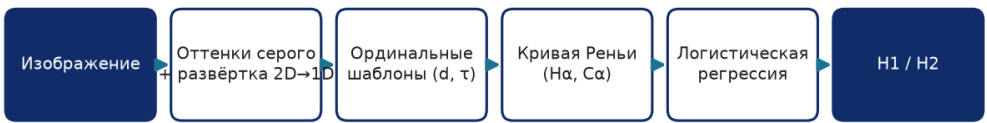
Задача



[СПИКЕР] Задача. Диффузионные модели порождают ошибки разной природы — от текстурных артефактов до семантических. Я изучаю, как параметры лёгкого дескриптора на основе сложности–энтропии влияют на оценку этих ошибок, и проверяю две гипотезы: H1 — отличить реальное от синтетического, H2 — отличить удачные генерации от неудачных. Справа — таксономия: чего от метода стоит ожидать. [ПОЯСНЕНИЯ] CE — порядковая статистика яркостей (какой пиксель больше соседнего); по ней энтропия и сложность. Семантические галлюцинации не меняют локальную статистику, поэтому метод их видеть не обязан.

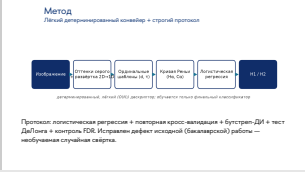
Метод

Лёгкий детерминированный конвейер + строгий протокол



детерминированный, лёгкий (O(N)) дескриптор; обучается только финальный классификатор

Протокол: логистическая регрессия + повторная кросс-валидация + бутстреп-ДИ + тест ДеЛонга + контроль FDR. Исправлен дефект исходной (бакалаврской) работы — необучаемая случайная свёртка.



[СПИКЕР] Метод. Изображение переводится в оттенки серого, разворачивается в сигнал, по нему строятся порядковые шаблоны и кривая Реньи; финальное решение даёт логистическая регрессия. Оценка — строгая: повторная кросс-валидация, доверительные интервалы, тест ДеЛонга, контроль ложных открытий. Работа продолжает мою бакалаврскую и исправляет её дефект — необучаемую случайную свёртку, дававшую шум. [ПОЯСНЕНИЯ] Все шаги, кроме классификатора, детерминированы и линейны по числу пикселей — отсюда «лёгкий». AUROC: 0.5 — случайность, 1 — идеал.

Дескриптор и его инвариантность

Окно 2×2 (яркости)

40	90
60	120

значения по возрастанию:
40 < 60 < 90 < 120

Порядковый шаблон

ранги (порядок):

(0, 2, 1, 3)

→ шаблон #k из 24

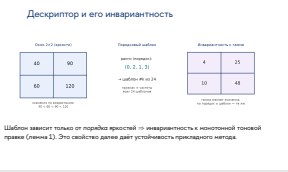
признак = частоты
всех 24 шаблонов

Инвариантность к гамме

4	25
10	48

гамма меняет значения,
но порядок и шаблон — те же

Шаблон зависит только от *порядка* яркостей ⇒ инвариантность к монотонной тоновой правке (лемма 1). Это свойство далее даёт устойчивость прикладного метода.



Шаблон зависит только от порядка яркостей ⇒ инвариантность к монотонной тоновой правке (лемма 1). Это свойство далее дает устойчивость прикладного метода.

[СПИКЕР] Сам дескриптор: в окне два на два смотрим относительный порядок яркостей — это порядковый шаблон, один из 24; признак изображения — частоты всех шаблонов. Ключевое: шаблон зависит только от порядка, поэтому изменение яркости или гаммы его не меняет. Это лемма 1, и именно она даёт устойчивость прикладного детектора. [ПОЯСНЕНИЯ] Справа та же область после гамма-коррекции: значения другие, порядок и шаблон те же. Этим ординальный подход отличается от методов на абсолютных интенсивностях.

Результаты

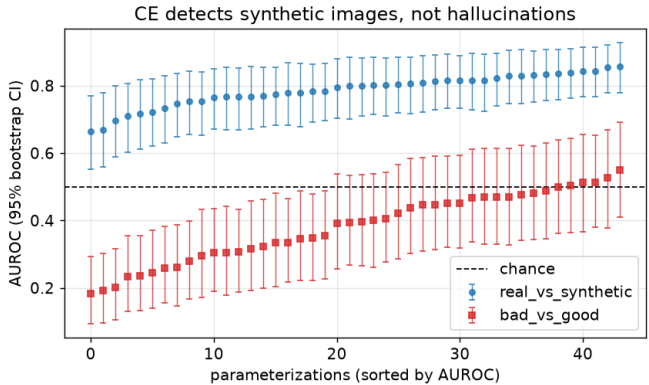
Сигнал есть для синтетичности, нет для галлюцинаций

H1

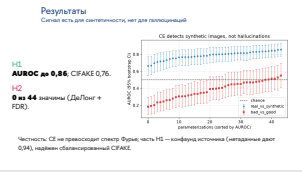
AUROC до 0,86; CIFAKE 0,76.

H2

0 из 44 значимы (ДеЛонг + FDR).



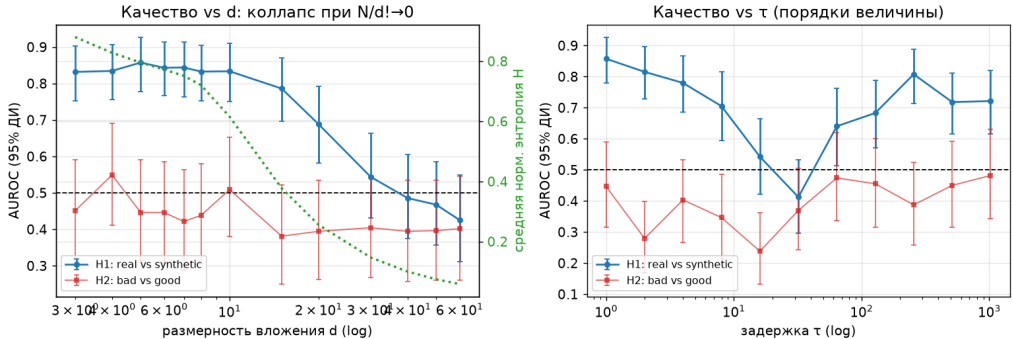
Честность: CE не превосходит спектр Фурье; часть H1 — конфаунд источника (метаданные дают 0,94), надёжен сбалансированный CIFAKE.



[СПИКЕР] Результаты. По H1 сигнал есть: AUROC до 0.86 и 0.76 на независимом CIFAKE. По H2 сигнала нет: из 44 конфигураций ни одна не превышает случайность значимо. Важно честно: CE не лучше обычного спектра Фурье, а часть внутридоменного H1 — это конфаунд источника, поэтому надёжнее сбалансированный CIFAKE. Вывод: метод измеряет синтетичность, семантические галлюцинации недоступны. [ПОЯСНЕНИЯ] H1 — реальное против синтетического; H2 — среди генераций удачные против неудачных. Конфаунд: метаданные файла (формат, разрешение, размер) сами разделяют классы с AUROC 0.94, то есть могли «подсказывать» ответ.

Результаты: влияние параметров

Качество управляется задержкой и схемой развёртки



$\tau = 1$ лучше; растровые схемы $>$ кривой Гильберта; потолок размерности d (статистика вырождается); резонанс при $\tau =$ ширине изображения.



τ = 1: лучше; растровые схемы > кривой Гильберта; потолок размерности d (статистика вырождается); резонанс при τ = ширине изображения.

[СПИКЕР] Параметрический анализ — это ядро темы. Качество определяется задержкой и схемой развёртки: единичная задержка лучше, строчный растр обходит кривую Гильберта. По размерности — жёсткий потолок: число шаблонов растёт факториально, статистика вырождается. И отдельная находка — резонанс качества, когда задержка равна ширине изображения: развёртка тогда сэмплирует вертикальных соседей. [ПОЯСНЕНИЯ] Для размерности d существует d! шаблонов; при d=10 это 3,6 млн — больше числа пикселей, поэтому оценка рассыпается. Резонанс связывает параметр с геометрией изображения.

Новизна: детектор дублирования

Применимый результат, устойчивый к тоновой маскировке

Локализация copy-move при тоновой правке вставки



Лёгкий детерминированный детектор-локализатор copy-move: **F1 0,93**, MCC 0,86. Устойчив к тоновой правке вставки (интенсивностный метод → случайность); инвариантен к отражению и повороту 90°.



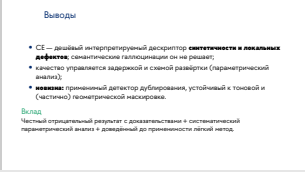
[СПИКЕР] Главная новизна. Из единственного положительного сигнала я довёл до конца прикладной метод — лёгкий детерминированный детектор-локализатор дублирования. С калиброванным порогом — F1 0.93, коэффициент Мэтьюса 0.86. Его преимущество выведено из доказанной инвариантности: он устойчив к подгонке яркости вставки, на которой интенсивностные методы падают к случайности; кольцевой вариант добавляет устойчивость к отражению и повороту на 90 градусов. На картинке: ординальный метод находит обе области, интенсивностный — ничего. [ПОЯСНЕНИЯ] Copy-move — подделка, когда фрагмент копируется внутри изображения. F1 — баланс точности и полноты; MCC устойчив при дисбалансе. Порог калиброван без утечки (train/val по изображениям).

Выводы

- CE — дешёвый интерпретируемый дескриптор **синтетичности и локальных дефектов**; семантические галлюцинации он не решает;
- качество управляется задержкой и схемой развёртки (параметрический анализ);
- **новизна:** применимый детектор дублирования, устойчивый к тоновой и (частично) геометрической маскировке.

Вклад

Честный отрицательный результат с доказательствами + систематический параметрический анализ + доведённый до применимости лёгкий метод.



[СПИКЕР] Итог. Кривые сложности–энтропии — дешёвый интерпретируемый дескриптор синтетичности и локальных текстурных дефектов; задачу семантических галлюцинаций он не решает. Качество управляется прежде всего задержкой и схемой развёртки. Новизна — применимый детектор дублирования, устойчивый к тоновой и частично геометрической маскировке. Вклад работы: честный отрицательный результат с математическим объяснением, систематический параметрический анализ и доведённый до применимости лёгкий метод. Спасибо за внимание. [ПОЯСНЕНИЯ] Для пятиминутного видео достаточно этих четырёх пунктов: задача, метод, результаты, новизна.